



天津大学
Tianjin University

基于深度学习的自监督定量光声层析成像 技术

Self-supervised Quantitative Photoacoustic Tomography based on deep learning

专业类别： 电子信息

研究领域： 生物医学工程

作者姓名： 吕一品

导师姓名： 李娇 副教授

企业导师： 李勇 副主任医师


答辩时间	2025 年 05 月 30 日		
答辩委员会	姓名	职称	工作单位
主席	周盛	研究员	中国医学科学院生物医学工程研究所
委员	任尚杰	副教授	天津大学
	侯雅竹	主任医师	天津中医药大学第一附属医院
	张童燕	副主任医师	天津中医药大学第二附属医院

天津大学精密仪器与光电子工程学院

二〇二五年六月

独创性声明

本人声明所呈交的学位论文是本人在导师指导下进行的研究工作和取得的研究成果，除了文中特别加以标注和致谢之处外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得 **天津大学** 或其他教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。

学位论文作者签名： 

签字日期： 2025 年 5 月 30 日

学位论文版权使用授权书

本学位论文作者完全了解 **天津大学** 有关保留、使用学位论文的规定。特授权 **天津大学** 可以将学位论文的全部或部分内容编入有关数据库进行检索，并采用影印、缩印或扫描等复制手段保存、汇编以供查阅和借阅。同意学校向国家有关部门或机构送交论文的复印件和磁盘。

（保密的学位论文在解密后适用本授权说明）

学位论文作者签名： 

导师签名： 

签字日期： 2025 年 5 月 30 日

签字日期： 2025 年 5 月 30 日

摘要

光声层析成像是一种兼具光学成像高对比度和超声成像大穿透深度的新兴影像技术。定量光声层析成像 (Quantitative Photoacoustic Tomography, QPAT) 旨在进一步解决光子能量非线性衰减问题, 定量获取深层组织的实际光学参数, 更精准地反映生物组织体的功能性信息。但是, 现有光学参数重建方法存在问题: 传统多模态联合成像方法由于引入其他成像设备, 对硬件要求过高; 使用光学求逆迭代模型的 QPAT 方法, 耗时较长且空间分辨率和定量精度无法兼得; 使用数据驱动的 QPAT 方法如深度学习模型近年得到广泛研究, 但因难以建立完备的复杂活体组织数据集, 导致实际应用受限。因此, 为突破目前 QPAT 重建瓶颈, 本文结合先验模型与数据驱动模型优势, 提出一种自监督 QPAT 算法 (Self-Supervised QPAT, SS-QPAT) 实现生物组织光学吸收参数图像的高分辨定量重建。

首先, 基于生成模型与光学求逆模型建立 SS-QPAT 模型框架。生成模型输入为固定值, 输出为预测光学吸收图像。使用蒙特卡洛模拟进行光学正向求解, 计算预测初始声压图像, 迭代反演逐步优化模型参数, 得到理想光学吸收参数预测值。其次, 为提高模型计算效率, 利用生成模型在迭代时优先拟合低频特征的谱偏移特性, 与蒙特卡洛模拟在光子数不足时保留低频结构信息的频谱特性, 引入自适应实例规范化、窗函数上采样等技术限制生成模型的频域边界, 不影响空间分辨率的同时, 降低蒙特卡洛模拟在迭代初始阶段的光子数。最后, 利用模拟实验证明 SS-QPAT 重建图像的准确性, 以及时间优化策略的有效性。

为了验证 SS-QPAT 的数据泛化性, 设计多个具有明显差异的跨域缺陷数据集, 分别使用 SS-QPAT 模型与传统端到端的 U-Net 模型在跨域缺陷数据集上训练, 建立混淆矩阵对比 SS-QPAT 与 U-Net 的重建结果。测试结果表明在数据分布有显著差异的情况下, 端到端模型全局学习能力受限, SS-QPAT 能够摆脱数据的依赖性, 在跨域数据上表现出高分辨定量重建能力。

最后, 对 SS-QPAT 进行仿体及生物实验验证, 先通过制作已知光学参数分布的“琼脂-脂肪乳-印度墨汁”仿体模型, 验证 SS-QPAT 在实际光声实验数据上的重建定量精度。接着, 进行离体组织与在体动物重建实验, 确定 SS-QPAT 在生物医学领域中的应用可行性。重建结果证明本文提出的 SS-QPAT 方法能够在无需数据驱动的情况下对多类数据完成高空间分辨率的光学参数定量重建, 为进一步开展深层组织光学研究探索提供新的解决方案。

关键词: 定量光声成像, 自监督去噪, 蒙特卡洛模拟, 生成模型

ABSTRACT

Photoacoustic tomography is a new imaging technology that combines the high contrast of optical imaging with the large penetration depth of ultrasonic imaging. Quantitative Photoacoustic Tomography (QPAT) aims to further solve the nonlinear attenuation problem of photon energy, quantitatively obtain actual optical parameters in deep tissue, and accurately reflect the functional information of biological tissue. However, the existing optical parameter reconstruction methods have the following problems: traditional multi-modal imaging methods introduce other imaging equipment, and have high hardware requirements. Optical inverse iterative QPAT method is time-consuming, and the spatial resolution and quantitative accuracy cannot be achieved simultaneously. Data-driven QPAT methods such as deep learning models have been widely studied in recent years. However, due to the difficulty of establishing a complete dataset of complex models of living tissues, their practical applications are limited. Therefore, in order to break through the bottleneck of QPAT reconstruction, we combine the advantages of prior model and data-driven model, and propose a Self-Supervised QPAT model (SS-QPAT) to achieve high-resolution optical absorption parameter quantitative reconstruction in deep biological tissues.

Firstly, the SS-QPAT model framework was established based on the generative model and the optical inversion model. Generative model input is a const matrix and the output is predicted optical absorption image. Monte Carlo simulation is used for optical forward solution, predict initial sound pressure image and gradually optimized model parameters, to obtain the ideal optical absorption parameter prediction. Secondly, to improve the computational efficiency, Using generative model spectral shift characteristics, and the Monte Carlo simulation result retain the spectral characteristics of low-frequency structure information when the number of photons is insufficient. Introduce techniques such as adaptive instance normalization and window function up sample to limit the frequency domain boundary of the generative model, to reduce the number of photons in the initial stage of the iteration of the Monte Carlo simulation and not affecting the spatial resolution. Finally, simulation experiments show the accuracy of the reconstructed image and the effectiveness of the time optimization strategy of SS-QPAT.

To improve the data-dependent performance of SS-QPAT, design multiple cross-domain defect datasets with obvious differences, Using the SS-QPAT model and the traditional end-to-end U-Net model trained on the cross-domain defect datasets respectively. establish confusion matrix to compare the reconstruction results of SS-QPAT and U-Net. The test results shown that the end-to-end model's global learning ability is limited when the data distribution is significantly different, and SS-QPAT can get rid of the dependence of data and show high resolution quantitative reconstruction ability on cross-domain data.

Finally, the SS-QPAT is verified by phantom and biological experiments. Firstly, the phantom model with known optical parameter distribution was made to verify the reconstruction quantitative accuracy of SS-QPAT on actual photoacoustic experimental data. Then, ex-vivo tissue and in-vivo animal reconstruction experiments were carried out to determine the feasibility of SS-QPAT application in the biomedical field. The reconstruction results show that the SS-QPAT method proposed in this thesis can complete the quantitative reconstruction of high spatial resolution optical data from multiple types of data without data-driven, and provide a new solution for further research and exploration of deep tissue optics.

KEY WORDS: Quantitative Photoacoustic Imaging, Self-Supervised Denoising, Monte Carlo simulation, Generative Model

目 录

第 1 章 绪论.....	1
1.1 引言.....	1
1.2 光声层析成像.....	2
1.3 定量光声成像研究现状.....	4
1.3.1 基于联合成像的吸收系数定量重建.....	4
1.3.2 基于先验模型的定量光声成像.....	5
1.3.3 基于数据驱动的定量光声成像.....	6
1.4 论文主要工作与结构安排.....	8
第 2 章 定量光声层析成像与深度学习的基础理论.....	9
2.1 组织体内的光学效应.....	10
2.2 正向光子传播模型.....	11
2.2.1 辐射传输方程模型.....	11
2.2.2 扩散近似方程模型.....	12
2.2.3 蒙特卡洛模拟模型.....	13
2.3 深层组织的光声传播理论.....	14
2.4 深层组织的定量光声重建算法.....	16
2.4.1 声学重建算法.....	17
2.4.2 光学重建算法.....	18
2.5 基于深度学习的图像生成原理.....	19
2.5.1 卷积网络基础.....	19
2.5.2 图像生成模型.....	20
2.6 本章小结.....	21
第 3 章 基于自监督深度学习的定量光声重建算法.....	23
3.1 基于 SS-QPAT 的定量光声成像方法.....	23
3.1.1 模型框架与重建流程.....	23
3.1.2 LYP-Net 的谱偏移特性.....	24
3.1.3 损失函数与优化设计.....	26
3.2 SS-QPAT 的迭代加速策略.....	28
3.2.1 欠光子蒙特卡洛模拟的频域特征.....	28

3.2.2 LYP-Net 优化与性能验证.....	31
3.2.3 频谱对齐优化策略.....	35
3.3 模型性能验证与跨域缺陷数据对比.....	36
3.3.1 基于数据驱动深度学习模型.....	36
3.3.2 跨域缺陷数据集.....	37
3.3.3 跨域数值模拟验证.....	38
3.4 本章小结.....	39
第 4 章 自监督深度学习定量光声成像实验验证.....	41
4.1 PAT 实验系统与误差校正.....	41
4.1.1 PAT 实验系统.....	41
4.1.2 系统误差校正网络.....	42
4.2 仿体模型验证.....	43
4.2.1 仿体设计与制作.....	44
4.2.2 仿体实验结果.....	45
4.3 离体组织与在体动物的自监督定量光声重建.....	47
4.3.1 离体组织定量光声重建.....	48
4.3.2 在体动物定量光声重建.....	48
4.4 本章小结.....	50
第 5 章 总结与展望.....	51
5.1 本文总结.....	51
5.2 工作展望.....	52
参考文献.....	55
发表论文和参加科研情况说明.....	63
致谢.....	65

第 1 章 绪论

1.1 引言

功能性成像是利用医学成像技术得到组织功能性参数,获取生物组织实际生理特征的成像技术。随着诊断技术的不断更新迭代,功能性成像已经成为继计算机断层扫描(Computed Tomography, CT)、超声成像(Ultra Sonic Imaging, USI)等传统成像技术后,医学成像领域的重要研究课题^[1]。随着计算机性能迭代与建模工具开发,基于功能性成像的自动化分析与病理预诊断等医疗病理辅助工具逐渐被广泛应用于术前诊疗、术中引导、术后观察等领域^[2]。

当前医用功能性成像领域的主要成像方法包括:核磁共振成像(Magnetic Resonance Imaging, MRI)、正电子发射断层扫描(Positron Emission Tomography, PET)、光学相干断层扫描(Optical Coherence Tomography, OCT)、近红外漫射光学层析成像(Diffuse optical tomography, DOT)等^[3]。MRI 是一种利用原子核在强磁场中受到射频脉冲后,质子因能态跃迁,释放电磁信号的成像技术, MRI 对水分子敏感,在软组织成像领域有着重要作用^[4]。但受限于核磁共振波谱原理,强磁场可能会导致携带金属辅助设备的患者无法使用,且检测时间相对较长,动态目标的伪影难以去除,无法实时监测生理参数变化。PET 是一种利用超短半衰期的放射性核素衰变时释放正电子的技术。术前向患者注射活性示踪标记物,随着标记物在体内代谢,于特定区域或病灶聚集,检测示踪剂浓度以反映生理特征^[5]。受限于外源性标记物需要体外注射的特点, PET 的空间分辨率与示踪剂浓度强相关,易出现辐射暴露问题,且难以满足功能性成像的时效性^[6]。OCT 是一种基于干涉原理,利用背向散射信号完成光学信息重建的成像技术,相对于传统的成像方法,具有微米级别的空间分辨率,广泛应用于眼科、皮肤、血管显微等领域^[7],但是由于光在人体组织内会因产生较强的散射,穿透深度只能达到毫米量级,无法完成针对深层组织的功能性成像。DOT 是一种利用生物组织的漫射光获取内部信息的影像技术,目前已经发展出连续波成像、脑功能成像、单光子检测、荧光分子成像等不同细分领域,但 DOT 受限于光学散射效应,难以获得高对比度的深层组织功能性图像^[8]。因此,目前亟需一种兼顾传统成像与光学成像优势,保持光高空间分辨率、高灵敏度的特性,能够稳定获取深层组织信息的无创在体新型生物医学功能性成像方法。

1.2 光声层析成像

光声成像（Photoacoustic Imaging PAI）是一种利用光声效应发展出的无创光学功能性成像技术，因其同时具有光学成像对组织体高对比度的特性与超声成像高分辨、高穿透的特性，在近几年得到了广泛研究与发展^[9]。其成像机理如图 1-1 所示，当短脉冲激光的能量被生物组织体吸收后，热膨胀的效率比热传导的速度更快，激发光的脉宽比压力膨胀与热膨胀的阈值更短，传播到组织体内部的光能被转化为机械动能，组织体的短时振动以机械波的形式向组织体外传播。该机械波即是光声信号，信号强度由待测目标的光学吸收特性决定，也即生色团浓度决定，利用信号强度分布的光学特征，广泛应用于纯光学成像的分子成像与功能性成像等不同任务。由于光声信号以机械波的形式向外扩散，生物组织体对超声信号的散射作用较小，避免了深层组织散射导致的信号混叠问题，获取深层组织高分辨光学功能成像信息。




图 1-1 光声成像机理^[9]。

面对不同的成像尺度和空间分辨率需求，PAI 发展出光声层析成像（Photoacoustic Tomography, PAT）、光声显微成像（Photoacoustic Microscopy, PAM）、光声内窥镜（Photoacoustic Endoscopy, PAE）等不同细分领域，以实现从组织体结构学信息到组织微结构、细胞学信息等不同检测任务^[10]。近年来随着对光声技术的进一步研究与探索，在多光谱测量、光谱解混、血氧重建等领域广泛发展，表现出重要的预临床研究价值。

PAT 成像技术属于 PAI 中针对深层组织体的结构性宏观成像技术，一般使用聚焦尺寸更长的低频超声换能器，使用与 CT 类似的扫描方法完成信号采集，在激光能量充足的情况下可以达到厘米级的成像深度，获得百微米的空间分辨率，实现血氧、代谢率等功能成像以及分子靶向光声成像。在成像应用方面，与 PAM、PAE 等成像方法相比，PAT 主要应用于组织学、器官等大视场任务，在如图 1-2

所示的小动物全身成像、乳腺癌早期诊断、肢体躯干血管成像等领域得到了广泛研究^[11]。在成像算法方面，随着计算机并行算力的提高和数学模型迭代，也衍生出稀疏通道光声层析成像^[12]、有限视场光声层析成像^[13]、多光谱光声断层扫描^[14]等发展性算法研究。




图 1-2 PAT 生物组织学成像：(a) 活体小鼠截断面 PAT 成像^[15]；(b) 人体乳腺深度血管三维 PAT 造影^[16]；(c) 人体前外侧大腿血管三维 PAT 成像^[17]。

光子在组织内输运过程中，因组织体的吸收效应，光子能量不断被待测目标体吸收，此类能量转换导致的光子能量衰减从组织结构上表现为：通常近表层组织释放出显著的光声信号，深部组织释放的光声信号逐步衰减。尽管光声信号能够通过时域特征区分浅层与深层信号，但对于实际的复杂生物组织结构，强度衰减与表层距离是非线性关系且难以准确预测。且 PAT 重建时使用与 CT、MRI 等影像技术类似的投影式重建算法，直接将超声换能器接收到的光声信号，按照球面扩散的形式，将声速投影至待重建的空间位置。如基于超声成像中波束成形发展得到的延迟求和（delay and sum, DAS）算法^[18,19]，Lihong V. Wang 等人提出针对光声的通用滤波反投影（Filtered Back-Projection, FBP）计算方法等^[20]。传统 PAI 重建算法无法排除光声信号的非线性衰减干扰，无法直接反映生物内部组织的光学吸收特性，在深层组织成像中表现更为明显，这类衰减大大限制了 PAT 的功能性定量重建能力。

1.3 定量光声成像研究现状

为重建与组织功能信息直接相关的光学吸收图像，定量光声层析成像技术（Quantitative Photoacoustic Tomography, QPAT）被提出用于解决 PAT 光通量不均匀衰减造成光学吸收系数难以定量的问题。虽然，传统多模态成像方法可通过采用 PAT 与 DOT 等光学成像设备结合的方式，实现组织光学参数定量重建，但联合成像系统硬件设备造价高，多模态成像匹配问题复杂，不利于应用推广。因此，QPAT 技术旨在传统 PAT 声学重建的基础上直接进行光学重建^[21]，通过光学逆问题求解预测光子在组织体内的传播过程，对深部目标体的光学参数量化求解，在肿瘤氧代谢表达、定量药物分布评估等功能性成像领域有着极高的研究价值。目前，实现组织光学吸收图像高分辨定量重建方法包括：基于联合成像的光学参数定量重建、基于先验模型的 QPAT 方法和基于数据驱动的 QPAT 方法等^[22]。

1.3.1 基于联合成像的吸收系数定量重建

基于联合成像的吸收系数定量重建方法，在 PAT 成像系统基础上引入其他成像设备，以获取组织体内部的量化光学参数信息，结合 PAT 的成像系统提供的结构信息，完成内部组织的光学参数定量重建。

此类方法利用 PAT 提供高空间分辨率的结构信息，DOT 提供组织内部的本征光学特征。如 Huabei Jiang 等将传统 PAT 测量系统与 DOT 测量系统相结合，分别采集声学重建分布信息与光子密度分布信息，证明了直接通过联合系统获取定量深层组织光学参数分布的可行性^[23]。Lihong V. Wang 与 Joseph P. Culver 等搭建了一种如图 1-3 所示的非接触式混合成像系统，该系统将 PAT 与 DOT 相结合，使用 DOT 系统得到低空间频率的光通量图像校正 PAT 系统光声图像的误差，得到吸收系数的精确定量分布^[24]。Sadreddin Mahmoodkalayeh 等提出一种 PAT 与 DOT 系统循环补偿的方法，使得两个系统能依靠各自的成像结果，微调系统的成像参数，得到具有更高分辨率和更精细空间细节的光学参数定量信息^[25]。也有研究使用其他成像技术完成近似的通量去除工作：如 Shuangyang Zhang 等提出了一种 PAT-MRI 混合成像系统，使用 MRI 相对清晰的结构学信息，划分重建信息中不同器官的分割边界，并利用 MRI 的分割结果调整 PAT 成像深层组织的光通量衰减，得到更清晰的解剖学与软组织信息^[26]。Leonie Ulrich 等将 PAT 系统与近红外光学断层扫描（Near-Infrared Optical Tomography, NIROT）相结合，开发出一种手持式联合成像设备，通过 PAT 系统解析高精度的血管光学吸收体，并使用 NIROT 去除背景中的光通量干扰，完成脑部简化模型的定量重建^[27]。




图 1-3 PAT-DOT 联合测量系统: (a)仿体模型; (b)PAT 采集子系统; (c)时域 DOT 系统^[24]。

传统联合成像吸收系数定量重建算法需要引入额外系统, 导致设备复杂, 环境限制较高, 且系统间的干扰和空间位置匹配是限制联合成像发展的主要因素, 为了突破硬件限制, 引入先验模型或使用数据驱动的 QPAT 算法, 是目前 PAT 成像系统完成光学参数定量重建的更优选择。

1.3.2 基于先验模型的定量光声成像

基于先验模型的 QPAT 方法在重建过程中引入光学正向模型, 模拟光子在组织体内的传播过程, 获得光子密度分布, 通过误差最小化的方式完成光学求逆, 解决传统 PAT 成像深层组织区域信号无法定量的问题。基于先验模型的 QPAT 方法主要使用辐射传输方程 (Radiative Transfer Equation, RTE)、扩散近似方程 (Diffusion Approximation, DA)、光子蒙特卡洛模拟 (Monte Carlo Simulation, MC) 等算法描述光子传播过程, 解决光学逆问题。

RTE 模型提供了光在生物组织内传播的高精度描述, 属于光学参数正向计算的典型算法, 但是基于 RTE 算法在计算过程中依赖多个微积分方程, 计算过程复杂算力消耗高, 不便于在大规模数据上并行计算, 高质量的成像结果被硬件设备条件限制。DA 模型属于 RTE 模型的简化算法, 相对于 RTE 模型降低了光学参数的计算压力, 但是 DA 模型是近似模型, 在组织边界会与实际结果产生较大误差^[28]。MC 模型属于一类统计学算法, 通过模拟光子包在目标体网格内的随机游走过程, 计算光子在组织体内的通量分布, 当光子数充足的情况下能够精确反映组织体光学特征, 但光子数与计算时间正相关, 高精度模拟算力需求大。

Guillaume Bal 等提出一种基于 RTE 的非迭代程序完成光学参数定量重建, 通过数理推导, 证明了模型能够唯一地重建出高精度光学系数, 在二维合成数据的数值重建中验证了其算法的准确性^[29,30]。Alexander V.等提出了一种使用 RTE 在多波长 QPAT 中的数值重建算法, 经由其推导的显式重建方案, 在数值模拟的多波长数据中验证了模型参数稳定性^[30]。Markus Haltmeier 等在使用 RTE 方程的基础上, 引入了一种相比于传统梯度计算更有效的随机近端梯度方法, 用求解多

线性逆问题的方式降低了求解 RTE 方程的计算压力^[31]。William C. Vogt 等人提出了一种在 DA 模型基础上改进的扩散偶极子模型 (Diffusion Dipole Model, DDM)，以实现计算成本更低的光学参数逆向推导，在生物仿体实验中，验证了该模型的光学参数推导能力^[32]。Niko Hänninen 等在光学重建过程中引入如图 1-4 所示的贝叶斯近似误差 (Bayesian Approximation Error, BAE)，补偿 DA 模型与理想光传输模型之间的差异，保证扩散方程在宽场成像范围内与实际值匹配，达到与真实目标体光学参数更为接近的效果^[33]。Aleksi A. Leino 等提出了一种基于 MC 模拟的微扰算法完成光学参数预测，在模拟血管数据上得到高质量重建结果^[34]。Niko Hanninen 等设计一种引入了拉普拉斯近似估计的自适应 MC 算法，数值模拟研究证明该模型得到精确解的计算成本更低^[35]。




图 1-4 扩散近似方程 QPAT 重建: (a)重建结果对比; (b)强度曲线; (c)单点强度^[33]。

目前基于先验模型的 QPAT 算法多通过光学正向模型预测值的误差，直接调整光学系数分布的预测值。随着模型迭代，光学参数预测值的定量精度逐步提升，空间分辨率逐步降低，且迭代收敛耗时长，导致算法适用范围受限。

1.3.3 基于数据驱动的定量光声成像

相比于使用先验模型 QPAT 方法，基于数据驱动的 QPAT 方法没有指定明确的光学正向模型，而是引入端到端的监督/半监督模型，通过真值标签与输入信息的映射关系调整中间层变量，完成光学逆问题的映射。

早期的数据驱动 QPAT 方法以使用传统机器学习方法为主，主要的实现方式是在模型算法特性的基础上引入人工先验，并基于人工条件先验消除 QPAT 中光子密度的干扰。Lili Zhou 等基于压缩传感的方法开发出一种基于字典的 K-SVD 方法进行光声数据预处理，通过实验结果对比，显著提高了重建图像的峰值信噪比^[36]。Teemu Sahlstrom 等基于自变分编码器设计了一种估计 QPAT 光学信息的

估计模型，并使用贝叶斯方法解决逆问题^[37]。Thomas Kirchner 等提出了一种基于机器学习的 QPAT 方法，利用体素光通量预测信息与周围体素的光声信号强度趋势设计上下文编码，采用随机森林回归器从上下文中预估光通量信息，最终通过实验验证该模型预测的准确性和鲁棒性^[38]。

近年，深度学习模型凭借其针对非线性任务的自适应性，无需手动设计特征，利用先验模型生成或人工标记建立数据集，直接从数据映射中自动提取逆向光学模型的底层结构特征，已成为目前基于数据驱动的 QPAT 模型主要实现方法^[39]。




图 1-5 基于数据驱动的 QPAT 模型典型实现方式：(a)光声信号采集训练数据；(b)先验模型参数训练标签；(c)在体信号采集测试数据；(d)数据驱动模型参数训练^[40]。

Christoph Dehner 等提出了一种如图 1-5 所示的 DeepMB 模型，使用光声设备获取数据，并使用先验模型迭代方式获取理想的参考图像。将参考信息作为深度学习模型的引导标签，完成多光谱光学参数的实时定量求解^[40]。Tingting Chen 等提出了一种基于 U-Net 改进的全卷积神经网络，使用宽场蒙特卡洛模拟生成网络所需的训练数据，在数值和仿体实验中，基于 U-Net 的 QPAT 模型表现出了更高的准确度和保真度^[41]。Cong Wang 等提出了一种使用多网络融合的 Q-OAT 模型，在模型计算层间引入光子密度分布作为光学参数的校准值，并添加半监督式数据风格转换网络（simulation-to-experiment end-to-end data translation network, SEED-Net）降低 PAT 实验系统的系统误差，使用仿体与动物模型重建出具有高空间分辨率的定量吸收分布图像^[42]。

虽然目前基于数据驱动的 QPAT 方法因其并行计算优势大大降低了硬件需求，但是基于数据驱动模型往往与训练集数据分布强相关，训练数据无法表征从声压分布信息到光子密度分布的全局映射关系。数据驱动的 QPAT 只能在小范围具有近似分布的测试数据中取得较为理想的效果，当数据分布差异较大时会出

现显著伪影。因此构建一种能够跨越训练数据分布限制的高质量光学参数定量模型，是目前基于数据驱动的 QPAT 技术研究重点之一。

1.4 论文主要工作与结构安排

为解决现阶段的 QPAT 重建算法迭代计算耗时高、监督模型泛化性差等研究瓶颈，发展出一种自监督深度学习模型（Self-Supervise Quantitative Photoacoustic Tomography, SS-QPAT）。采用数值模拟、仿体和生物实验分别验证 SS-QPAT 的有效性和准确性，证明了其在实际光声预临床研究中的应用潜力。

本文的各章节安排如下：

第一章为绪论：首先，介绍目前生物医学影像学发展现状，引出 PAT 作为一种新兴影像技术，相比于其他成像技术的优势。接着，说明 PAT 各类细分研究方向，说明 QPAT 的研究意义与技术迭代，梳理传统联合成像吸收系数定量重建方法和先验模型、数据驱动等 QPAT 光学逆问题重建方法。最后，简述本文纲要。

第二章为 QPAT 与深度学习的基础理论：首先，介绍光子在组织体内吸收散射理论，随后，介绍 RTE 方程、DA 方程、MC 模拟等正向光学模型，进而，介绍光声信号在组织体内的扩散原理，再介绍与正向过程对应的逆问题的求解方法，最后，介绍目前数据驱动 QPAT 中深度学习模型的基础理论与典型应用。

第三章为自监督深度学习定量光声重建模型的设计方案：首先，说明本文 SS-QPAT 模型的整体结构，随后，分析 SS-QPAT 中的生成模型的频谱偏移特性与 MC 模型缺乏光子重建时的频域特征，在生成模型中引入限制频域范围的归一化、上采样、通道注意力等计算层，降低迭代开始阶段 MC 模型需要的光子数，将重建速度提升至近实时水平。最后，与端到端式数据驱动 QPAT 模型在跨域数据集上对比结果，验证本文 SS-QPAT 模型在跨域分布数据上的高泛化定量能力。

第四章为 SS-QPAT 模型的实验验证：首先，介绍本文使用的 PAT 实验系统与 SEED-Net 系统误差校正网络，随后，制造“琼脂-脂肪乳-印度墨汁”模型进行仿体实验数值验证，证明从 PAT 实验系统到 SS-QPAT 模型的光学参数定量重建是可行的。最后，设计离体动物组织模型、在体小鼠生物模型、在体肿瘤小鼠模型，验证 SS-QPAT 在离体组织与在体动物上的光学参数定量重建效果，证明本文提出的 QPAT 重建算法的预临床应用能力。

第五章为总结与展望：简述本文工作内容，并对主要成果与创新点进行细分总结。分析目前模型的隐性问题与不足，展望未来工作与研究方向。

第2章 定量光声层析成像与深度学习的基础理论

QPAT 技术旨在解决 PAT 技术中,组织体内光子强度不均匀衰减,深部组织光学参数难以进行量化评估的问题。QPAT 的求解过程如图 2-1 所示:分别为图 2-1(a)所示,描述光声信号传播的正向光学过程与正向声学过程,与图 2-1(b)所示, PAT 的声学逆问题与 QPAT 的光学逆问题两大部分。

声学逆问题对应 PAT 的光声信号传播过程,涉及光声转换机理、光子在组织体内的传播与能量转换、光声信号传播特性、反射式信号重建等技术。

光学逆问题对应 QPAT 的光通量去除过程,涉及组织体内光子特性、光子输运模型、统计学光子模型等技术。

本文提出的 SS-QPAT 模型属于先验模型类与数据驱动类 QPAT 的混合算法,还涉及深度学习模型的基本原理、典型超参数设计、损失函数与优化器参数迭代实现、典型网络结构特征等内容,后文通过以上技术建立本文的自监督模型。




图 2-1 QPAT 问题纲要: (a)正向声学/光学模型; (b)逆向声学/光学模型。

2.1 组织体内的光学效应

光子在生物组织的传播过程中会接触到生物体组织的内源性生色团，因生色团类别与浓度按不同概率发生光学吸收和散射，产生从光能到热能与机械能的能量转化。在 QPAT 或 DOT 领域，主要使用组织体的生色团浓度来表征对应位置的吸收系数。对于图 2-2(a)所示的组织体内的水、脱氧/富氧血红蛋白、乏氧/富氧肌红蛋白、脂肪、胆红素、黑色素等生物内源性物质，都具有代表性的吸收特征光谱^[43]。通过表征这些生物内源性的吸收光谱，反推出对应点位的生物组织类型。由于人体背景大部分为水，对于 200~380 nm 的近紫外区，多类内源性物质表现出高量级的强散射特性，难以穿透至深层组织，且对内源性遗传物质表现出一定的光毒性^[44,45]。对于 1000~1700 nm 的近红外二区，尽管此波段的低散射特性使光子具有更长的自由程，但因水具有较高的吸收峰，其他内源性物质吸收偏低，缺乏合适的显影技术。对于 670~1000 nm 的近红外一区，内源性物质与背景具有显著差异、具备解混特征且散射相对较低，是目前 QPAT 成像典型选用的成像光学窗口^[46]。除了内源性物质，也会使用如图 2-2(b)所示具有不同摩尔吸收系数与噪声摩尔浓度外源性标记物，满足不同灵敏度特征的光程补偿，与内源生色团不敏感组织的功能性检测任务。




图 2-2 典型活性物质光谱特性：(a)内源性物质吸收光谱；(b)外源性标记吸收系数^[43]。

内源性成分可以通过特定波长下的光学吸收特性参数 μ_a 表述， μ_a 代表光子 在介质中行进单位长度后被介质吸收的概率，一般以 mm^{-1} 作为其计算单位，其 定义与内源性生色团的关系可由式(2-1)表示：

$$\mu_a(\lambda) = \sum_{i=1}^i C_i \cdot \alpha_i(\lambda) = \sigma_a(\lambda) \cdot \rho_a \quad (2-1)$$

其中 C_i 表示第 i 类生色团浓度； $\alpha_i(\lambda)$ 表示在波长 λ 下第 i 类生色团的摩尔吸收系数； $\sigma_a(\lambda)$ 表示波长 λ 时的光子吸收截面； ρ_a 表示组织体吸收粒子密度； $\mu_a(\lambda)$ 表示波段为 λ 时的光子在经过该体素时，被体素吸收的概率。

光在组织体内的传播过程中，另一重要作用机制是光子的散射作用，与的吸收作用类似，一般以光学散射特性参数 μ_s 表述，并以 mm^{-1} 作为单位。可使用与 μ_a 定义近似的方法表述，如式(2-2)所示。

$$\mu_s(\lambda) = \sigma_s(\lambda) \cdot \rho_s \quad (2-2)$$

其中 $\sigma_s(\lambda)$ 表示波长为 λ 时的光子吸收截面； ρ_s 表示组织体散射粒子密度。

对于复杂生物组织，光子具有较为显著的前向特征。直接使用 μ_s 表示组织的散射特性，会高估散射降低的光传播深度阈值，为修正这种前向偏置，引入使用各向异性参数 g 修正的约化散射系数 μ'_s 描述实际生物组织对光的散射^[47]。目前 μ'_s 与 μ_s 的计算关系与 μ'_s 的近红外区的一般经验公式如式(2-3)所示。

$$\mu'_s(\lambda) = \mu_s(\lambda) \cdot [1 - g(\lambda)] = C_1 \cdot \lambda^{-C_2} + C_3 \cdot \lambda^{-C_4} \quad (2-3)$$

其中 $\mu_s(\lambda)$ 表示波长为 λ 时的散射系数； $g(\lambda)$ 表示各向异性参数 $[-1,1]$ ，在生物组织的典型值在 0.7 至 0.98； $C_1 \sim C_4$ 表示 μ'_s 的经验参数，因散射体尺寸分布与波长的相互作用， μ'_s 在近红外区与波长均呈现出反对数分布趋势^[48]。

2.2 正向光子传播模型

QPAT 技术使用光学正向模型描述光在组织体内的传播过程，消除光子能量密度分布对 PAT 技术造成的干扰。为了实现光学求逆，需要选择与重建算法匹配的正向模型，设计光学逆向求解器或生成配对的标签映射。目前广泛使用的光学正向模型可以分为基于光子输运理论的连续型模型，如辐射传播方程 RTE、扩散近似方程 DA 等；和基于离散统计学模型设计的光子蒙特卡洛模拟 MC 等。

2.2.1 辐射传输方程模型

RTE 方程是一种使用光子输运理论，以粒子的方式描述光子分布的方法。RTE 方程是目前 QPAT 获得光子密度分布解析解的重要手段。由于 QPAT 的光学过程中不涉及光子的波动效应，不会产生光子极化、辐射电离与非弹性散射过程，可以将 RTE 方程的能量守恒写作式(2-4)所示的形式：

$$\begin{aligned} \frac{1}{c} \frac{\partial \phi}{\partial t}(\nu, \hat{s}, t) = & q(\nu, \hat{s}, t) + \mu_s(\nu) \int_{4\pi} \phi(\nu, \hat{s}', t) \cdot \Theta(\hat{s} \cdot \hat{s}') d\hat{s}' \\ & - [\hat{s} \cdot \nabla + \mu_a(\nu) + \mu_s(\nu)] \phi(\nu, \hat{s}, t) \end{aligned} \quad (2-4)$$

其中 $\phi(v, \hat{s}, t)$ 表示光子在空间体素 v ，传播方向 $\hat{s}$ ，时刻 t 的状态时，光子携带的平均光子能量密度； $q(v, \hat{s}, t)$ 表示光子激发时的平均光子能量密度，即光源状态； $\Theta(\hat{s} \cdot \hat{s}')$ 表示光子从传播方向 $\hat{s}$ 转换到传播方向 $\hat{s}'$ 的相位函数，用于描述光子传播过程中的角度变化； c 为光速。通过式(2-4)可知：在体素 v 到 $\hat{s}$ 方向的小区域内，光子能量随时间 t 的能量变化率由激发源能量 $q(v, \hat{s}, t)$ 、光子的净流出量 $\hat{s} \cdot \nabla$ 、光子的吸收量 $\mu_a(v)$ 、光子的散射量 $\mu_s(v)$ 、其他方向散射至该体素光子 $\phi(v, \hat{s}, t) \cdot \Theta(\hat{s} \cdot \hat{s}')$ 的球谐积分共同决定。

由于 PAT 使用短脉冲作为激发源，激发时间窗口足够短，机械波引起的声学传播相比于热效应累积的热传播高出多个数量级，可以忽略时间变化对 RTE 方程的影响，即将式(2-4)改写为式(2-5)的形式。

$$q(v, \hat{s}) + \mu_s(v) \int_{4\pi} \phi(v, \hat{s}') \cdot \Theta(\hat{s} \cdot \hat{s}') d\hat{s}' = [\hat{s} \cdot \nabla + \mu_a(v) + \mu_s(v)] \phi(v, \hat{s}) \quad (2-5)$$

其中 $\phi(v, \hat{s})$ 用于表示组织体被 PAT 系统的短脉冲激光照射时，在空间体素 v ，传播方向 $\hat{s}$ 产生的光子能量密度累积。通过式(2-5)可知：光子能量不随时间变化时（即 $\partial \phi(v, \hat{s}, t) / \partial t = 0$ 时），RTE 方程也满足能量守恒公式。QPAT 光学逆运算所需的光通量可由式(2-6)所示光子能量密度所有角度的累积值描述。

$$\varphi(v) = \int_{4\pi} \phi(v, \hat{s}') d\hat{s}' \quad (2-6)$$

其中 $\varphi(v)$ 表示单次短脉冲激光激发下，空间体素 v 处的光通量，一般会作为模型的弱函数，在有限元划分的离散网格中完成 $\varphi(v)$ 计算。

2.2.2 扩散近似方程模型

由于 RTE 方程是包含空间角度多个独立变量的微积分方程，实际求解过程中难以快速获得解析解，为了降低计算压力，一般会在 QPAT 的光学逆问题求解过程中使用 RTE 方程的简化模型 DA，快速获取光通量 $\varphi(v)$ 的近似值。

DA 方程会将光子辐射进行球谐近似处理，并在迭代 N 次后强行截断光子计算。由于生物组织体具有高散射特性，一般会使用与时间无关的 P1 近似，将各个体素的弥向源 $q_0(v)$ 与有向源 $q_1(v, \hat{s}')$ 简化为式(2-7)所示^[49]。

$$\begin{cases} q_0(v) = \mu_a(v) \cdot \varphi(v) + \nabla \cdot \int_{4\pi} \phi(v, \hat{s}') \cdot \hat{s}' d\hat{s}' \\ q_1(v, \hat{s}') = [\mu_a(v) + \mu_s'(v)] \int_{4\pi} \phi(v, \hat{s}') \cdot \hat{s}' d\hat{s}' + \frac{1}{3} \nabla \cdot \varphi(v) \end{cases} \quad (2-7)$$

其中 $\mu_s'(v)$ 为约化散射系数， $\varphi(v)$ 为对应体素的光通量。且 $\mu_s'(v) \gg \mu_a(v)$ 作为

DA 方程适用的约束条件，在满足约束条件的前提下，视散射的光通量是各向同性的，也即 $q_1(v, s')=0$ ，最终将 DA 方程转化为式(2-8)所示简化形式。

$$q_0(v) = \mu_a(v) \cdot \varphi(v) - \nabla \cdot [3[\mu_a(v) + \mu'_s(v)] \cdot \nabla \cdot \varphi(v)] \quad (2-8)$$

对于任意非均匀介质，通过有限元标准数值解求解式(2-8)获得近似的光通量 $\varphi(v)$ ，对于均匀介质，可以将 DA 方程的 $\varphi(v)$ 约束至式(2-9)的特解^[50]：

$$\varphi(v) = \int_{4\pi} G_0(v, v') q_0(v') dv' \quad (2-9)$$

其中 $G_0(v, v')$ 为三维格林函数，可通过式(2-10)所示空间吸收系数 $\mu_a(v)$ 、约化散射系数 $\mu'_s(v)$ 、体素关系 $|v - v'|$ 、有效衰减系数 $\sqrt{3\mu_a(v)(\mu_a(v) + \mu'_s(v))}$ 等参数表示。

$$G_0(v, v') = \frac{3[\mu_a(v) + \mu'_s(v)]}{4\pi|v - v'|} \cdot e^{-|v - v'| \sqrt{3\mu_a(v)(\mu_a(v) + \mu'_s(v))}} \quad (2-10)$$

求解式(2-8)与式(2-9)，即可完成 DA 方程计算。DA 方程主要用于远光弥散照明条件，因 PAT 系统一般使用近光宽场照明完成信号激发，会导致有限元边界的误差较大，为了得到精确结果，目前更多使用 MC 模型描述光子的传播过程。

2.2.3 蒙特卡洛模拟模型

相比于使用确定模型的 RTE 方程与 DA 方程，MC 模拟属于基于统计学的随机模型，在光子包路径充分覆盖网格时，即可获得 $\varphi(v)$ 的精确估计，是目前 PAT 研究领域确定组织 $\varphi(v)$ 的金标准^[51]。传统 MC 方法一般会模拟光子能量从发射到完全吸收的全部过程，导致光子进行过多无意义迭代；为了降低光子包计算量，发展出引入方差减少技术（Variance Reduction Technique, VRT）、轮盘赌边界阈值（Russian Roulette, RR）、光子分裂等方法，提高计算效率并弥补提前截断造成的边界误差^[52]。本文采用并行 MC 模拟流程如图 2-3 所示，设定体素网格与源探信息，将连续光子离散为光子包并行计算，利用光子在组织体内的吸收与散射特性，独立计算每个光子包在体素网格内的光通量累积值，得到有限元网格对应的光子强度分布信息。

光子会按照光源特性设置初始权重 w_0 ，在有限元网格内按照每个网格的吸收与散射特性，进行如式(2-11)所示的光子能量转化，完成 $\varphi(v)$ 累积。

$$\varphi(v) = \sum_{v'}^{N(v)} w \cdot (1 - e^{-\mu_a(v) \|v - v'\|}) \quad (2-11)$$

其中 $N(v)$ 表示空间体素 v 的邻域； w 表示光子权重； $\|v - v'\|$ 表示体素内的移动距离。即遍历各个邻域到当前体素的光子，并按体素内的移动距离累积 $\varphi(v)$ 。

同时每个光子会通过 $\mu'_s(\mathbf{v}) \cdot \|\mathbf{v} - \mathbf{v}'\|$ 的方式计算剩余步长，当光子步长小于阈值时，重置光子步长并按照目前的角度进行如式(2-12)所示的角度更新。

$$\begin{cases} \vartheta = 2\pi \cdot m_1 \\ \theta = \arccos \frac{1}{2g} \left[1 + g^2 - \left(\frac{1 - g^2}{1 - g + 2g \cdot m_2} \right)^2 \right] \end{cases} \quad (2-12)$$

其中 ϑ 与 θ 代表按照各项异性参数 g 随机产生的经纬角； m_1 与 m_2 代表 0-1 分布的随机数。将原角度 $\hat{s}(\vartheta_0, \theta_0)$ 更新至 $\hat{s}'(\vartheta', \theta') = \hat{s}'(\vartheta_0 + \vartheta, \theta_0 + \theta)$ ，能量转化与角度调整后，对光子包进行 $\|\mathbf{v} - \mathbf{v}'\|$ 位置更新以进行下一次迭代。

光子包随着式(2-11)与式(2-12)不断进行光子吸收、光子散射与光子位置更新迭代，光子权重 w 不断衰减，当 w 下降到截断阈值 w_{th} 时引入 RR 边界判别，按照剩余权重进行随机光子删除与权重倍增。对于 256×256 的模拟网格，需要使用 10^8 以上的光子包完成有限元体素模拟，由于各个光子包在模拟过程中互不影响，因此 MC 模拟便于使用多线程或图形加速的方式并行计算，目前已经发展出多类并行 MC 方法，极大提高了光子计算效率^[53]。同时，由于体素 $\|\mathbf{v} - \mathbf{v}'\|$ 不限制于正六面体，衍生出使用四面体网格专门处理复杂边界条件的模拟方法^[54,55]。




图 2-3 并行光子 MC 模拟流程。

2.3 深层组织的光声传播理论

PAT 的光声转换过程可通过能量守恒表示，周期性短脉冲激光照射目标体时，生色团吸收光子能量发生能量转化。短脉冲激光产生的能量类型与受激时间相关，

可使用如式(2-13)所示的压力弛豫时间 τ_s 与热弛豫时间 τ_{th} 描述能量转换特性。

$$\tau_s = \frac{d_c}{v_s}, \tau_{th} = \frac{d_s^2}{\partial_{th}} \quad (2-13)$$

其中 v_s 为介质的声速； ∂_{th} 为热扩散率； d_c 为介质对应的特征尺寸； τ_s 为介质受激后产生的机械波回归稳态所耗费的时间，若短脉冲的激光脉冲宽度为 τ_p ，当 τ_p 远小于 τ_s 时，机械波的传播过程视为瞬时的振动，即压力隔离状态； τ_{th} 为介质受激后的热能通过热传导在介质间扩散所耗费的时间，当 τ_p 远小于 τ_{th} 时，单个体素内的能量不会发生热扩散，即热隔离状态。

PAT 实验系统中 τ_p 一般设置为 10 ns，满足压力隔离和热隔离条件，发生绝热膨胀。组织体能量守恒通用公式可按式(2-14)表示：

$$\beta \Delta T = \kappa \Delta P + \frac{dv}{v} \quad (2-14)$$

其中 β 为体积膨胀系数， ΔT 为温度变化量， κ 为同温压缩率， ΔP 为压力变化量， dv/v 为体积膨胀变化量，由于组织体在高频短脉冲激光照射下满足压力隔离条件，能够忽略 dv/v 的影响，此时 κ 可由式(2-15)表示：

$$\kappa = \frac{C_p}{\rho v_s^2 C_v} \quad (2-15)$$

其中 ρ 为组织的质量密度， C_v 为等体比热容， C_p 为同压比热容。对于温度变化量 ΔT ，可以通过如式(2-16)所示的光热能量转化公式描述：

$$\Delta T = \eta_{them} \frac{\mu_a \phi}{\rho C_v} \quad (2-16)$$

其中 η_{them} 为描述光能转换为体积膨胀和热能比例的光热转换效率，当满足压力隔离与热隔离状态时 η_{them} 趋近于 1。通过式(2-14)、式(2-15)、式(2-16)整理得：

$$\Delta P = \frac{\beta \Delta T}{\kappa} = \mu_a \phi \frac{\beta v_s^2}{C_p} = \mu_a \cdot \phi \cdot \tau \quad (2-17)$$

其中 $\tau = \beta v_s^2 / C_p$ 为格日尼森系数(Grüneisen constant)，在本文视为定值，组织体的每个有限元受到光源瞬时激发时的初始声压 $\Delta P = P_0$ ，由式(2-1)描述的光学吸收系数分布 μ_a ，由式(2-6)、式(2-9)或式(2-11)描述的光子密度分布 ϕ ，由式(2-14)、式(2-15)描述的格日尼森系数 τ 共同决定。

为了描述组织体内光声信号的扩散传播，使用的压力密度、质量守恒、动量守恒，建立如式(2-18)所示的光声波动方程，描述生物组织内部机械波传播过程：

$$\nabla^2 P(v, t) - \frac{1}{v_s^2} \frac{\partial^2}{\partial t^2} P(v, t) = - \frac{\beta}{\kappa v_s^2} \frac{\partial^2 T(v, t)}{\partial t^2} \quad (2-18)$$

其中 $P(v, t)$ 表示在位置 v , 时刻 t 时的声压特性, $T(v, t)$ 表示该位置时刻的温度特性, 当生色团浓度与光学吸收系数呈线性关系时, 引入如式(2-19)所示的光子吸收能量 $H(v, t)$ 描述组织的光热转换。

$$H(v, t) = \eta_{them} \cdot \mu_a(v, t) \cdot \varphi(v, t) \quad (2-19)$$

满足(2-1)压力隔离与热隔离条件时, 可以通过式(2-18)、式(2-19)得到式(2-20)。

$$\nabla^2 P(v, t) - \frac{1}{v_s^2} \frac{\partial^2}{\partial t^2} P(v, t) = -\frac{\beta}{C_p} \frac{H(v, t)}{\partial t} \quad (2-20)$$

因光声波动方程满足点源叠加性和线性叠加性, 可将式(2-19)改写为式(2-21)。

$$H(v, t) = \int H(v', t') \cdot \delta(v - v') \cdot \delta(t - t') dv' dt' \quad (2-21)$$

引入式(2-10)所示格林函数 $G(v, t; v', t')$ 求解得式(2-22)所示的光声波动方程。

$$\nabla^2 G(v, t; v', t') - \frac{1}{v_s^2} \frac{\partial^2}{\partial t^2} G(v, t; v', t') = -\delta(v - v') \delta(t - t') \quad (2-22)$$

因光声波动方程视为无界空间, 满足因果性和推迟效应, 可以使用延迟格林函数描述 $G(v, t; v', t')$, 将式(2-22)改写为式(2-23)。

$$G(v, t; v', t') = \frac{\delta \left[|t - t'| - \frac{|v - v'|}{v_s} \right]}{4\pi |v - v'|} \quad (2-23)$$

式(2-23)表示机械波以声速 v_s 传播时, 延迟 $|v - v'|/v_s$ 时刻, 到达体素位置。通过式(2-20)与式(2-21)将压力场 $P(v, t)$ 表示为格林函数 $G(v, t; v', t')$ 与光子吸收能量 $H(v, t)$ 的卷积, 其结果整理如式(2-24)所示。

$$P(v, t) = -\frac{\beta}{C_p} \int G(v, t; v', t') \frac{\partial H(v', t')}{\partial t'} dv' dt' \quad (2-24)$$

式(2-20)至式(2-24)描述了光声信号在组织体内的传播特性, 在实际计算过程中, 为了降低计算压力, 一般会将格林函数法求解的光声波动方程, 拆分成耦合一阶偏微分方程组, 引入频率幂律前置因子调整吸收与散射特性。

2.4 深层组织的定量光声重建算法

QPAT 为了完成生物组织功能性成像, 涉及到光学与声学的物理特性, 在参数重建时往往将算法划分为声学重建算法与光学重建算法两部分。PAT 的光声信号传播满足格林函数应用条件, 可使用反投影算法完成声学重建, 光声信号的能量强度与光在组织内的作用机理有关, 可使用光学求逆模型迭代求解。

2.4.1 声学重建算法

QPAT 的声学重建算法与光声波动传播模型对应，超声换能器在组织体外部接收到组织受激释放的光声信号序列 $P_s(v, t)$ ，换能器按照不同空间排布，组成在空间上闭合的非凹曲面 S ，重建曲面内零时刻声压分布 $P(v, t)_{t=0}$ 。PAT 的光声信号可视为球面波信号，成像区域内的组织受到激发后，能量会以激发点为球心，向外部空间均匀扩散。利用这种扩散特性，发展出使用基于反拉登变换 (Inverse Radon, IR) 的点源投影算法、由 DAS 发展的滤波反投影 FBP 算法与使用基于模型 (Model Base, MB) 的误差最小化算法等，本文主要采用 FBP 重建算法完成 PAT 数据的声学反演，其主要原理如下。

若将式(2-24)的波动方程的传播方式视为无界空间内的均匀扩散，即以点 v 为球心，按照球面随着时间间隔 $\Delta t = |v - v'|/v_s$ 向组织外部均匀传播。若在外部的空间位置上存在一闭合曲面 S ，曲面 S 的每个点都随时间 t 采集光声信号序列 $P_s(v, t)$ ，利用光声信号的传播特性可推得初始声压 $P(v, t)_{t=0} = P_0(v)$ 如式(2-25)所示。


$$P_0(v) = \frac{1}{\omega} \int_S \left[2P_s(v', t') - 2t' \frac{\partial P_s(v', t')}{\partial t'} \right] d\omega \bigg|_{t'=t-\frac{|v-v'|}{v_s}} \quad (2-25)$$

其中 ω 代表闭合曲面 S 中空间点的立体角积分， $d\omega$ 代表探测器之间的线元或面元，并由曲面 S 的立体角表示。式(2-25)可通过图 2-4(a)进一步解释。

FBP 的重建过程如图 2-4(b)所示：红色虚线闭合曲面的换能器阵列采集到的时域光声信号序列，以探测点为球心，反向球面扩散至外部空间，由于 PAT 信号对闭合曲面内所有角度均匀扩散，每个点探测器均能够通过时间反演 $|v - v'|/v_s$ 将初始光声信号反向散播至信号发生区域，曲面内的多点重建如式(2-26)所示。

$$\begin{cases} \lim_{d\omega \rightarrow 0} \frac{1}{\omega} \sum_{v' \in S} d\omega \cdot P_s(v, |v - v'|/v_s) = P(v) \rightarrow P_0(v) \\ \lim_{d\omega \rightarrow 0} \frac{1}{\omega} \cdot d\omega \cdot P_s(v, |v - v'|/v_s)_{v' \in S} = P(!v) \rightarrow 0 \end{cases} \quad (2-26)$$

其中 v 为闭合曲面内投影体素， $!v$ 为闭合曲面内非投影体素， v' 为闭合曲面换能器空间体素，多点 FBP 重建可视为式(2-25)的离散形式。随着换能器采样点的增加，每个采样点的空间角 $d\omega \rightarrow 0$ ，信号源体素的光声信号强度逐步接近实际初始声压 $P_0(v)$ ，其他位置体素是闭合曲面 S 中的探测器 v' 随机抽样，当 $d\omega \rightarrow 0$ 时其他位置体素的重建信号 $P(!v) \rightarrow 0$ ，体素之间的信号满足叠加性，在重建时互不干扰，能够实现闭合曲面内部初始声压分布 $P_0(v)$ 的精确重建。


 图 2-4 FBP 重建原理：(a)投影过程^[56]；(b)环阵换能器重建模拟。

2.4.2 光学重建算法

光学重建算法是在声学重建算法的基础上，利用逆向光学模型从 $P_0(v)$ 重建 $\mu_a(v)$ 的过程。通过式(2-24)可知，满足绝热膨胀条件时，信号源的光子能量强度 $H(v)$ 与 $P_0(v)$ 呈现比例关系，且通过式(2-19)可知 $H(v)$ 与吸收系数 $\mu_a(v)$ 与光子密度 $\phi(v)$ 相关， $\phi(v)$ 与组织吸收散射相关，可将式(2-19)改为式(2-27)。

$$H(v; \mu_a(v), \mu'_s(v), g(v)) = \eta_{them} \cdot \mu_a(v) \cdot \phi(v; \mu_a(v), \mu'_s(v), g(v)) \quad (2-27)$$

为了在 $H(v)$ 中重建 $\mu_a(v)$ ，目前主要通过基于先验模型的 QPAT 方法实现，此类方法利用 2.2 节的光子正向模型，通过 $\mu_a(v)$ 的估计值计算 $\phi(v)$ 的估计值，并利用误差最小化方法的完成 $\mu_a(v)$ 与 $\phi(v)$ 的逆向光学迭代。可将这类模型算法描述为式(2-28)。

$$(\hat{\mu}_a(v), \hat{\mu}'_s(v)) = \arg \min_{(\mu_a(v), \mu'_s(v))} \left[\left\| P_0(v) - C \cdot \mu_a(v) \cdot \phi(v; \mu_a(v), \mu'_s(v)) \right\|^2 \right] \quad (2-28)$$

其中 $\hat{\mu}_a(v)$ 与 $\hat{\mu}'_s(v)$ 为通过误差最小化重建的光学参数预测值； C 为一常值，由格日尼森系数 τ 、热转换系数 η_{them} 、系统状态等参数共同决定； $\phi(v; \mu_a(v), \mu'_s(v))$ 代表光子正向传播过程，可由式(2-6)为主的 RTE 方程、(2-9)为主的 DA 方程、(2-11)为主的 MC 模拟完成计算，因生物体内各向异性参数 $g(v)$ 数值差异较小，一般不会将其作为误差最小化算法的变量参与迭代，通过式(2-28)循环迭代计算光学参数分布的理想预测。

基于先验模型的 QPAT 光学重建算法在重建过程中，会受到正向光子模型特性的影响：使用 RTE 驱动的光子预测模型能够获得光学参数的理想估计，但因方程内包含微积分方程的特点，需要消耗大量计算才能完成；使用 DA 方程相比于 RTE 方程，降低了模型的计算量，但受 DA 模型应用范围受限，在距离光源较近的表层区域有较大误差；MC 模拟为统计学模型，将光学传播过程离散为光子包的传播过程，光子路径覆盖所有空间体素时，可视为正向光子模型的无偏估

计,但需要进行大量光子包计算才能得到精确解,对计算设备的并行运算能力要求较高。为解决传统误差最小化中出现的问题,普遍在迭代过程中引入人工约束条件,如将 $\hat{\mu}_a(v)$ 与 $\hat{\mu}'_s(v)$ 等参数分布约束在有限多项式空间或有限三角多项式空间中的空间约束,使用 L1/L2 正则化进行稀疏学习等^[57],也有在重建过程中引入动量优化、自适应优化等迭代式凸优化方法^[58]。不过传统使用先验模型的方式都属于人工经验先验,仅符合常见生物组织 $\hat{\mu}_a(v)$ 的分布规律,无法保证在特殊分布下依然成立,发展出空白矫正、点源扩散函数(Point Spread Functions, PSF)等影像辅助技术,优化 QPAT 光学重建的先验特征^[59]。

2.5 基于深度学习的图像生成原理

自 Frank Rosenblatt 等与 Paul Werbos 等提出感知机,并在其基础上引入反向传播(Back Propagation, BP)算法后^[60,61],以梯度反向传播为核心的多层感知机(Multi layer Perceptron, MLP)成为求解监督性非线性问题的一大重要工具^[62]。传统 MLP 可以抽象为多个全连接层的嵌套组合,全连接层将 X 维数据映射至 Y 维需要进行 $X \cdot Y$ 次计算,尤其将数据扩展至二维映射时计算压力更高。Yann Lecun 等将二维卷积代替全连接层引入 BP 算法^[63] [64]。借助卷积的局部连接性,对于 X 维数据使用卷积核只需要进行 $K \cdot Y$ 次计算,且凭借卷积的空间不变性,在多级拼接后能够对多尺度特征表现出更强的泛化能力。

以 MLP 为基础的深度学习算法自 Alex 等验证其在图像分类任务中的表现力后^[65],在目标检测、语义分割、图像生成等任务中得到快速发展。随着硬件设备并行计算能力的提高,近年,在针对长文本的自然语言处理(Natural Language Processing, NLP)方向延伸出词嵌入、语音迁移、语义识别等广泛研究的细分领域,已成为目前机器学习监督类算法中的一大重要技术。

2.5.1 卷积网络基础

卷积神经网络(Convolutional Neural Network, CNN)是一种具有局部感知特性的计算模型,相比于传统 MLP 中的全连接(Fully Connected, FC)层, CNN 极大地降低了计算消耗,其前向计算过程如图 2-5(c)所示,使用单个卷积核 K ,在输入图像 X 的横纵坐标上进行局部点积计算,每个位置点积后得到输出层 Y 。卷积的梯度反向传播过程如图 2-5(a)与图 2-5(b)所示,无论是输出层 Y 到卷积核 K 权重的梯度还是输出层 Y 到输入层 X 的梯度,只需要计算输出宽高 $y_w \cdot y_h$ 乘卷积核 $w_w \cdot w_h$ 宽高次计算,再将计算后的特征矩阵在 $y_w \cdot y_h$ 空间维度进行一次求和即可完成卷积对自身权重或前置计算层的梯度计算。相比于 FC 层计算梯度时需要

$y_w \cdot y_h \cdot x_w \cdot x_h$ 次计算, CNN 层的计算复杂度降低两个维度。除了传统 CNN 算子, 还衍生出使用 1×1 的单点卷积与通道尺度卷积进一步降低 CNN 计算量的深度可分离卷积^[66]、获得更大感受野的空洞卷积^[67]等。




图 2-5 卷积计算与梯度传播: (a)输出到权重反向梯度计算; (b)输出到输入反向梯度计算; (c)二维卷积前向计算^[68]。

前向计算层除了使用卷积进行提取特征之外, 还会在特征提取阶段使用池化层 (Pooling) 降低特征矩阵的宽高维度, 并在特征融合时采用上采样 (Upsample) 扩展特征矩阵的宽高维度。卷积通过提取不同尺度下的像素特征, 完成对整个输入图像的量化求解。目前, 深度学习模型为了进一步提升有效特征的提取能力, 在网络特征层间发展出跳连接残差 (Residual Block)、密集连接 (Dense Block)、通道混洗 (Channel Shuffle) 等多个计算层组合的计算块。随着对网络特征提取效率的进一步研究, 引入以全局池化为基础的压缩激励 (Squeeze Excitation, SE)^[69]、卷积选择 (Selective Kernel, SK)^[70]等模块解决传统 CNN 受到局部感受野限制的问题。近年, 基于多头自注意力机制的乘性注意力大大提升了对复杂特征的提取能力^[71], 衍生出大量改进模型。

由于 CNN 普遍使用点积计算, 为了拟合高阶非线性映射关系, 还会在层间插入激活函数, 将计算图扩展至其他函数域。如二分类问题中的 Sigmoid 函数, 在 Sigmoid 上改进的双曲正切 Tanh 函数, 防止梯度消失的 Leaky ReLU 等, 目前计算图中的激活函数 $F(x)$ 都具有激活函数的梯度 $dF(x)/dx$ 直接由原函数的权重值 $F_{Grad}(x)$ 计算的特性, 即 $dF(x)/dx = F_{Grad}(F(x))$, 快速完成链式计算。

2.5.2 图像生成模型

图像生成作为深度学习的重要子问题, 自 Alec Radford 等设计深度卷积生成对抗模型 (Deep Convolution Generative Adversarial Network, DCGAN) 后, 生成器-鉴别器结构得到广泛发展。相比于 CNN 模型学习条件概率密度 $P(Y|X)$, 生成判别模型学习联合概率密度 $P(X, Y) = P(Y|X) \cdot P(X)$ 。针对不完整数据分布

的弱独立任务，生成判别模型能够更准确地提取数据的相似度分布，得到更接近实际数据的结果。

生成模型的基础任务是生成媲美真实数据的图像，基于 DCGAN 改进的 StackGAN，利用两个生成器组合的方式完成了高分辨率的图像生成^[72]。在其基础上改进的 ProGAN 引入了逐级提升分辨率的生成模型，逐步从低像素扩展至高分辨率，保证了图像生成的稳定性^[73]。为了定量控制不同尺度特征，StyleGAN 将生成器分为映射网络和融合网络两个模型，为不同图像分配索引，经过映射网络获得潜在编码^[74]，再经过融合网络提取各级特征，完成风格解耦^[75-77]。

其他基于 GAN 模型的方向，衍生出以循环一致性损失（Cycle Loss）为核心的风格迁移任务，该模型使用一对生成器与判别器建立双向映射，实现非对称数据的风格转换，是目前解决 PAT 模拟域与实验域系统误差的重要手段。并发展出将生成器拆分为编码器和解码器，以完成多类风格迁移的 ComboGAN^[78]、通过融合图像与风格标签，添加潜在编码和风格编码，实现多对多风格转换的 StarGAN^[79]等。也有生成模型向着轻量化的方向发展，如用于图像压缩与去噪的 DIP 模型^[80]。

随着扩散模型的发展和长文本模型的广泛应用，词嵌入技术也已成为目前 GAN 模型的热门改进方向，如 Minguk Kang 等在 StyleGAN 的基础上提出的 GigaGAN^[81]，在生成器特征融合前，将文本信息映射为词向量，并通过映射网络将词向量融合至潜在编码，使得生成器能够根据文本输入调整输出图像。也有模型将音频生成任务融入生成模型中，如 Shijia Liao 等提出了结合神经声码器的 EVA-GAN^[82]，得到高保真重建音频。

2.6 本章小结

本章从 QPAT 的正向问题入手，介绍光子在深层组织内的光学输运过程，并列举了描述组织体内光学传播模型的 RTE 方程、DA 方程、MC 模拟等方法。通过波动方程说明初始声压产生后光声信号在组织中传播过程，实现正向光声模型构建。为完成 QPAT 从声信号到声压图像再到光学参数图像的逆向求解，介绍典型声学重建算法的实现方法，以及初始声压图像重建后逆向光学模型的光学参数重建算法。最后，介绍本文所采用的深度学习网络模型，以及典型计算层的实现方式与梯度计算原理。

第3章 基于自监督深度学习的定量光声重建算法

声学重建的声压分布图像由组织光学吸收系数分布和光子强度分布共同决定。由于光子强度分布与组织光学参数之间存在非线性耦合，这种耦合关系会导致光学逆问题求解时产生交叉干扰误差，从而影响 QPAT 的重建精度。目前在常见的重建方法中，基于先验模型的 QPAT 方法难以快速完成具有高空间分辨率的光学参数定量重建，基于数据驱动的 QPAT 方法会受训练集限制，难以得到足够泛化的模型，只能将成像应用限制在与训练数据集近似的任务中。

本文提出一种融合光子正向模型与生成模型的自监督定量光声重建算法 SS-QPAT 具有迭代耗时短、空间分辨率高、数据泛化能力强等特点。SS-QPAT 使用光通量削减先验网络（Luminous flux Yield Prior Network, LYP-Net）作为生成模型，生成的吸收系数输入光子蒙特卡洛（MC）模拟，共同生成光声图像，通过生成图像与实际图像的差异，迭代重建物体吸收系数分布图像。本文提出的 SS-QPAT 模型不依赖数据集训练，能够实现高分辨率定量吸收系数分布重建。

提出“频域对齐”训练策略，通过降低初始迭代阶段 MC 模拟消耗的光子数，减少了 MC 模拟的迭代时间，快速完成高分辨率光学参数定量重建。

最后，通过模拟仿体、模拟组织、模拟小鼠三个跨域数据集，验证了 SS-QPAT 模型与传统需要数据集驱动的 U-Net 模型的泛化能力。实验结果表明，本文提出的 SS-QPAT 摆脱了训练数据分布特征干扰，在不同数据域中表现出高分辨率的定量重建能力。

3.1 基于 SS-QPAT 的定量光声成像方法

本节设计了 SS-QPAT 的结构与方法，具体为：首先，设计了 SS-QPAT 总体框架，其主要由 LYP-Net 与 MC 模拟两部分组成，说明 SS-QPAT 迭代求解的全部过程。随后，分析了 LYP-Net 的频谱偏移特性，验证其具有优先拟合低频结构信息的特点。最后，对 SS-QPAT 的混合损失函数与其他超参数进行了设计优化。

3.1.1 模型框架与重建流程

自监督定量光声模型 SS-QPAT 由光通量削减先验网络 LYP-Net 与 MC 模拟组成，整体框架如图 3-1 所示，分为前向计算和逆向计算两个过程。

LYP-Net 用于生成光学吸收系数预测值 μ_a 。本网络以各向同性白噪声（零均

值单位方差高斯分布) 作为网络的输入, 其频谱特征与目标图像无相关性, 经过多个计算块, 将白噪声转换为预测 μ_a 。MC 模拟接收来自 LYP-Net 输出的 μ_a , 生成 LYP-Net 对应的预测 P_{0_P} , 完成 SS-QPAT 的前向计算。

SS-QPAT 的逆向计算过程如下: 模型通过实验得到的光声图像 P_{0_T} 与该轮次下生成的预测 P_{0_P} 计算一致性误差, 迭代预测 P_{0_T} 对应的理想 μ_a 。从图中可以看出, 一致性误差直接调整 LYP-Net 的参数, 这是因为在光子包充足且光源和模拟体素中的光学参数确定的情况下, MC 模型生成的光通量预测值是确定的, 可使梯度选择性跳过 MC 模型直接调整 LYP-Net 参数, 且不会对 LYP-Net 造成梯度混淆。当 P_{0_P} 与 P_{0_T} 一致时, 预测 μ_a 与 P_{0_T} 对应的理想 μ_a 也会保持一致, 完成光学吸收系数的自监督定量重建。




图 3-1 SS-QPAT 框架。

3.1.2 LYP-Net 的谱偏移特性

光通量衰减先验网络 LYP-Net 的基础结构如图 3-2 所示, 近似于图像重建网络的生成模型。网络输入为符合高斯分布的 $8 \times 8 \times 256$ 固定潜在编码, 在网络初始化阶段将潜在编码即设定为固定值。网络的整体架构由多个不同尺度的计算块以线性排列的方式组合而成。计算块由上采样层、卷积激活层和残差连接层组成, 利用上采样层调整特征矩阵的宽高维度, 并利用残差块完成不同维度特征的跳跃连接, 最后由卷积激活层完成特征提取。

卷积激活层由激活函数、 3×3 二维卷积、边界翻转和 Dropout 裁剪层组成, 计算过程如式(3-1)所示。

$$x_{out} = pad(Relu(x_{in}) \times k + b, p) \cdot M \quad (3-1)$$

其中 x_{in} 和 x_{out} 表示权重的输入与输出, $Relu$ 表示激活函数, k 和 b 表示卷积核的权重和偏置, pad 表示边界翻转操作, p 表示翻转范围, M 表示 Dropout 操作对应的 01 掩码矩阵, 该矩阵与前级计算层输出逐元素相乘。

潜在编码随着各级计算块的前向计算, 特征图的权重尺寸将按照 $8 \times 8 \times 256 \rightarrow 16 \times 16 \times 256 \rightarrow 32 \times 32 \times 256 \rightarrow 64 \times 64 \times 256 \rightarrow 128 \times 128 \times 256 \rightarrow 256 \times 256 \times 256 \rightarrow 256 \times 256 \times 1$ 的计算方式, 完成 μ_a 的分布预测。神经网络的迭代过程具有不受监督学习标签影响的频谱偏移特性, 即在深度学习模型的迭代过程中, 模型会优先拟合低频规律性结构信息, 随后再缓慢拟合无序的噪声信号。




图 3-2 LYP-Net 模型基本结构。

为了探索 LYP-Net 的谱偏移特性, 制作白噪声标签与数字鼠横切面结构标签, 构建混合噪声与结构信息的混噪标签。标签尺寸均为 256×256 , 在迭代过程中不引入其他模型辅助, 直接使用 LYP-Net 拟合单张图像, 除了标签外的其他训练参数均保持一致, 迭代过程如图 3-3 所示。

图 3-3(b)展示了三组测试标签在 LYP-Net 网络中迭代不同轮次后, 网络重建出的拟合结果。图 3-3(a)展示了三组预测值随迭代到混噪信息的距离, 使用欧氏距离 D_e 衡量图像预测结果与真实结果之间的差异, 其公式如式(3-2)所示, $x_{i,j}$ 和 $\hat{x}_{i,j}$ 表示网络的预测值与真实值, m 和 n 表示图像尺寸。

$$D_e = \sqrt{\frac{1}{m \times n} \sum_i^m \sum_j^n (x_{i,j} - \hat{x}_{i,j})^2} \quad (3-2)$$

对于结构信息, LYP-Net 进行 $1e^2$ 轮次迭代后基本恢复到肘点; 对于白噪声信息, 需要 $1e^5$ 轮次迭代后才能近似到达肘点。对于混噪信息, 在迭代过程中可划分为两个过程: 在前 $1e^2$ 轮次时, 得到与结构标签近似的结构信息; 至 $1e^5$ 轮次时, 得到与结构标签一致的结构信息。因此, LYP-Net 对结构信息表现出显著的拟合倾向。噪声通常是高频信息, 所以 LYP-Net 对低频信息较为敏感。

与此同时，利用 LYP-Net 的低通特性，还可以提高其图像生成的效率。这是因为生物组织结构图像以低频的规律性信息为主，通过选取合适的截停轮次，就可以获得质量较好的结构预测图像。




图 3-3 LYP-Net 谱偏移特性：(a)各类预测到混噪标签的距离；(b)各类预测迭代典型值。

3.1.3 损失函数与优化设计

SS-QPAT 的模型结构需要跨模型（梯度选择性跳过 MC 模型，直接调整 LYP-Net 参数）连接梯度，对异常值扰动较为敏感。本文使用一种基于广义损失函数^[83]设计的混合损失函数，作为 SS-QPAT 的体素损失 $Loss_p$ ，如式(3-3)所示：

$$Loss_p = \frac{|\alpha - 2|}{\alpha} \left[\left(\frac{1}{|\alpha - 2| \cdot M} \sum_{i,j} \left(y_{i,j} - \hat{x}_{i,j} \odot MC(\hat{x}_{i,j}) \right)^2 + 1 \right)^{\alpha/2} - 1 \right] \quad (3-3)$$

其中 $\hat{x}_{i,j}$ 表示 LYP-Net 的预测值； MC 表示蒙特卡洛模拟过程； $y_{i,j}$ 表示实验系统重建或模拟测试的初始声压分布标签； M 表示重建图像的所有像素体素； α 是控制广义损失迭代策略的形状参数，如图 3-4 所示，将 $y_{i,j} - \hat{x}_{i,j} \odot MC(\hat{x}_{i,j})$ 视为体素之间相互独立的误差间距，当 $\alpha=1$ 时广义损失函数退化为近似 Huber 损失，当 $\alpha=2$ 时广义损失函数退化为 MSE 损失。

Huber 损失是一种按照区间选取 L1 或 L2 正则项的损失函数，如图 3-4(a)所示，在误差较大情况下为 L1 平均绝对误差损失 MAE，能够有效防止梯度过大出现异常值，避免参数围绕目标平面连续波动。Huber 损失在误差接近目标值的情

况下为 L2 均方误差损失 MSE，由于 MSE 的误差梯度变化趋势在目标平面附近连续可微，能有效避免模型微调时的抖动问题。

尽管 Huber 损失在误差间距较大时能够有效避免过冲，但如图 3-4(b)所示，此时导数是常数，模型迭代的初始阶段，难以高效快速地收敛。因广义损失函数中参数 α 具有平滑且连续的特性，本文选取一种结合 Huber 损失和 MSE 损失的方式，将 α 的参数设定为 1.5，整体结构更接近 MSE 损失。如图 3-4(b)所示，当 $\alpha=1.5$ 且 $Loss_p$ 的梯度较小时， $Loss_p$ 近似为 MSE 损失，在梯度较大时， $Loss_p$ 近似为 MSE 与 MAE 的混合损失，保证面对不同类别的误差，损失函数都能确保网络的参数稳定高效的收敛。




图 3-4 $Loss_p$ 参数特征：(a) $Loss_p$ 的输出分布；(b) $Loss_p$ 的导数分布。

声压图像的结构信息具有连续的低频特征，相比于纯噪声的随机抖动，幅值的积分结果更为显著，为了解决 $Loss_p$ 在计算过程中，体素之间信息相互独立的问题，引入全变差约束降噪损失^[84]。全变差约束降噪损失 $Loss_v$ 如式(3-4)所示，利用体素间的信息进行自动降噪，进一步提高网络对高频噪声抑制能力。

$$Loss_v(Z) = \sum_{i,j}^M \left(\left(\hat{z}_{i+1,j} - \hat{z}_{i,j} \right)^2 + \left(\hat{z}_{i,j+1} - \hat{z}_{i,j} \right)^2 \right)^{1/2} \quad (3-4)$$

其中 Z 表示分布矩阵，可以代表 LYP-Net 生成的吸收系数预测图像，也可以代表经过 MC 模拟生成的初始声压预测图像， $\hat{z}_{i,j}$ 表示预测图像中每体素的位置。

最终 SS-QPAT 的损失 $Loss_s$ 如式(3-5)所示，由体素损失 $Loss_p$ 、吸收系数变差损失 $Loss_v(X)$ 、光通量变差损失 $Loss_v(X \odot MC(X))$ 三部分共同组成。

$$Loss_s = Loss_p + \beta \cdot Loss_v(X) + \gamma \cdot Loss_v(X \odot MC(X)) \quad (3-5)$$

其中 β 和 γ 表示两类变差损失在损失函数中所占权重，通过实验调整将两个参数设定为 $3.3e^{-2}$ 以平衡单体素与体素间的损失贡献， X 表示 LYP-Net 的吸收系数预测图像，利用以上损失组合，能够确保 SS-QPAT 模型的稳定迭代。

网络迭代过程中,使用自动平衡一阶矩和二阶矩估计信息的 Adam 优化器作为本文的优化算法,优化器的一阶矩与二阶矩衰减参数 β_1 、 β_2 设定为经验参数 0.9 和 0.999;网络的初始学习率设定为 $1e^{-3}$,并采用梯度衰减学习策略防止迭代后期出现参数抖动的情况,学习率衰减间隔为 200 Iter,衰减幅度为 0.71,平衡计算效果后,将 3000 Iter 作为网络训练的终止条件。

SS-QPAT 在 Python3.11.1 工作环境训练,使用 Pytorch2.4.1 深度学习框架建立生成模型,使用 PMCX0.2.6 工具包实现 MC 模拟,工具包在工作环境下编译安装,在 Debian20.04、NVIDIA GeForce RTX 3090Ti 的双 GPU 硬件环境中完成后文对 SS-QPAT 自监督深度学习框架模型的测试与验证。

3.2 SS-QPAT 的迭代加速策略

在 SS-QPAT 的迭代策略中,每次迭代均需使用大量光子包进行 MC 模拟,往往需要数十个小时才能获得高精度的吸收系数预测结果。为提升 SS-QPAT 模型的迭代效率,本节研究欠光子条件下 MC 模拟的频谱特性,并根据其特性进一步改进 LYP-Net 模型结构。为 LYP-Net 引入自适应实例规范化(Adaptive Instance Normalization, AdaIN),降低网络的迭代次数;设计 Sinc 窗函数正弦基上采样(Windowed Sine Cardinal Up Sampling, WS-UP)方法,以提升 MC 模型与 LYP-Net 的匹配度;设计层间自注意力机制,提升各尺度特征的利用率。改进后的 LYP-Net 所呈现出的频域迭代特性,与使用少量光子进行 MC 模拟呈现出的频域特性表现一致,基于此特点,提出“频域对齐”优化策略,显著降低 SS-QPAT 在初始迭代阶段消耗的光子数,使 SS-QPAT 重建速度提升了 51.1 倍。

3.2.1 欠光子蒙特卡洛模拟的频域特征

MC 模拟需要使用足量光子包获得光通量的精确预测,由于光子包数量与模拟时间正相关,导致想要获得光通量分布需要大量时间。欠光子数的 MC 模拟能够显著提高模拟速度,但光子数的减少会引入高频噪声,导致重建质量下降。如图 3-5(a)所示,创建 $256 \times 256 \times 200$ 的体素网格,进行欠光子 MC 模拟,光源设定为 Z 轴中心二维切面边缘向平面中心照射的宽场光源。组织体的光学吸收、散射、各向异性、折射率均按 Z 轴柱状分布,取 Z 轴中心切面(图 3-5(a)红色框线所在平面)的光通量分布作为模拟结果。使用均方根误差 RMSE、峰值信噪比 PSNR、结构相似指数 SSIM 作为本章以及后续章节的评价指标。

RMSE 是一种在 MSE 基础上发展的评价指标,用于将结果压缩至规定区间内,越接近 0 说明特征图与目标越接近,如式(3-6)所示。

$$RMSE(\mu, \hat{\mu}) = \sqrt{\sum_{i=1}^W \sum_{j=1}^H [\hat{\mu}(i, j) - \mu(i, j)]^2} / \sqrt{\sum_{i=1}^W \sum_{j=1}^H \mu(i, j)^2} \quad (3-6)$$

$PSNR$ 是一种评价图像结构特性的经典指标, 以 dB 为单位, 如式(3-7)所示。

$$PSNR(\mu, \hat{\mu}) = 20 \times \lg \left[\text{ceil} \sqrt{W \times H} / \sqrt{\sum_{i=1}^W \sum_{j=1}^H [\mu(i, j) - \hat{\mu}(i, j)]^2} \right] \quad (3-7)$$

$SSIM$ 兼顾图像之间亮度差异 $l(\mu, \hat{\mu})$ 、对比度差异 $c(\mu, \hat{\mu})$ 以及结构差异 $s(\mu, \hat{\mu})$ ^[85], 能够更加平衡地衡量图像之间的关系, 如式(3-8)所示。

$$SSIM(\mu, \hat{\mu}) = [l(\mu, \hat{\mu})]^\alpha \cdot [c(\mu, \hat{\mu})]^\beta \cdot [s(\mu, \hat{\mu})]^\gamma \quad (3-8)$$

其中 α 、 β 、 γ 表示三类差异所占权重, 三类差异计算方法如式(3-9)所示。

$$\begin{cases} l(\mu, \hat{\mu}) = \frac{2E_\mu E_{\hat{\mu}} + C_1}{E_\mu^2 + E_{\hat{\mu}}^2 + C_1} \\ c(\mu, \hat{\mu}) = \frac{2\sigma_\mu \sigma_{\hat{\mu}} + C_2}{\sigma_\mu^2 + \sigma_{\hat{\mu}}^2 + C_2} \\ s(\mu, \hat{\mu}) = \frac{\sigma_{\mu\hat{\mu}} + C_3}{\sigma_\mu \sigma_{\hat{\mu}} + C_3} \end{cases} \quad (3-9)$$

上式中 ceil 表示图像可达到的最大值 (归一化数据为 1), E_x 表示图像的灰度平均值, σ_x 和 $\sigma_{\mu\hat{\mu}}$ 表示图像方差与的协方差, C_1 、 C_2 、 C_3 为趋近于 0 的常量, 防止三类差异出现除零错误, 导致数据异常。

欠光子 (光子数为 $1e^3$) 的 MC 模拟到足量光子 (光子数为 $1e^8$) 的评价指标变化情况如图 3-5(b) 所示, 随着光子数的增加, $RMSE$ 逐渐下降, $PSNR$ 、 $SSIM$ 逐渐提升。典型光子数 (光子数为 $1e^3$ 、 $1e^4$ 、 $1e^5$ 、 $1e^6$ 、 $1e^7$) MC 模拟的重建结果如图 3-5(c) 所示, 展示了 MC 模拟随着光子数增加, 光子路径逐步覆盖所有体素, 消除高频噪声从而得到理想预测值的全过程。

图 3-5(b) 的不同光子数模拟耗时表明, MC 模拟时间基本与光子数线性相关, 获得理想模拟结果需要消耗较长时间。由于 SS-QPAT 每次迭代都会调整 LYP-Net 的参数权重, LYP-Net 输出的预测 μ_a 也会发生变化, 为了确保预测 μ_a 与预测 P_{0_P} 能够严格对应, 每次迭代都需要重新使用大量光子包进行 MC 模拟。这种迭代策略导致 SS-QPAT 的吸收系数重建速度极为缓慢, 无法满足实际需求。




图 3-5 欠光子 MC 模拟对照：(a)MC 模拟体素、光源设定；(b)欠光子 MC 模拟评价指标与时间消耗；(c)特定光子 MC 模拟结果。

欠光子 MC 模拟的重建信息经过如式(3-10)所示的离散傅里叶变换，得到时域图像对应的频谱分布 $z_{u,v}$ 。

$$z_{u,v} = \sum_{w,h} x_{w,h} \cdot e^{-i2\pi\left(\frac{uw}{\sqrt{M}} + \frac{vh}{\sqrt{M}}\right)} \quad (3-10)$$

表征光子重建初始声压分布的二维幅度谱如图 3-6(a)所示，欠光子 MC 模拟时，仅有低频部分频谱与理想模拟效果频谱匹配，高频部分表现为随机分布的噪声；随着光子数的增加，高频频谱的噪声逐渐消失，重建频谱信息有着向高频扩展的趋势。将二维频谱转化为一维频谱，不同光子模拟的一维频谱特征与理想光子 MC 模拟频谱特征的误差信息如图 3-6(b)所示，横坐标为频率分布，纵坐标为光子数分布。可以进一步验证此结论：在欠光子条件下，MC 模拟损失的是高频信息，这个损失会随着光子数的增加而逐渐降低。




图 3-6 欠光子 MC 模拟频谱特征：(a)特定光子 MC 模拟二维频谱与重建范围；(b)欠光子 MC 模拟一维频域误差。

3.2.2 LYP-Net 优化与性能验证

本节进一步修改 LYP-Net 结构，保证其频谱偏移特征的稳定性与鲁棒性，为 3.2.3 节频域对齐优化策略奠定基础。

在 LYP-Net 前向计算过程中，使用串联排布的计算块从固定的潜在编码逐步上采样完成图像重建，上一个计算块输出的结果直接输入到下一个计算块中。这种没有约束的逐级计算结构，会导致前几个计算块的小尺寸误差不断向后续的计算块累积，在迭代的初始阶段产生如图 3-7(a)所示的液滴伪影^[76]，网络需要大量迭代才能定量恢复光学参数分布。

为了消除液滴伪影，减少迭代次数，引入自适应实例规范化 AdaIN，限制计算块之间的误差干扰^[86]，该模块计算方法如式(3-11)所示：

$$AdaIN(W_n, W_{n+1}) = \sigma(W_{n+1}) \frac{W_n - \mu(W_n)}{\sigma(W_n)} + \mu(W_{n+1}) \quad (3-11)$$

其中 $\sigma(W_n)$ 和 $\mu(W_n)$ 表示特征矩阵 W_n 的均值和标准差，在以上采样划分的各级模块之间插入该模块，平衡各级计算层的权重占比。

相较于传统的批量规范化 (BN) 计算方法，AdaIN 包含对上一级计算层权重去风格化以及与当前计算层统一风格化这两个约束，使得 AdaIN 能够迅速消除各级计算权重之间的局部异常值，避免误差逐级传递。采用 BN 的迭代结果如图 3-7(b)所示，经过 1000 轮迭代后，重建图像依然存在大量伪影；采用 AdaIN 的迭代结果如图 3-7(c)所示，经过 1000 轮迭代后，重建图像的伪影干扰基本消失，且与经过 3000 轮迭代后的重建图像分布大致相同。AdaIN 模块显著减少了 SS-QPAT 的迭代轮次，能够快速恢复结构信息。




图 3-7 AdaIN 计算层：(a)液滴伪影；(b)BN 规范化重建；(c)AdaIN 规范化重建。

sinc 函数在频域上可以视作一个理想的低通滤波器，相比于双线性上采样，有着更显著的高频限制效果，能够提升图像质量。由此，基于 sinc 函数设计了一种上采样方法，优化 LYP-Net 对低频信息的生成效果。由 sinc 函数得到的上采样卷积核权重分布如式(3-12)所示。

$$\text{sinc}_{i,j} = \frac{\sin(\pi i)}{\pi i} \cdot \frac{\sin(\pi j)}{\pi j} \quad (3-12)$$

进一步，尽管 sinc 的极限趋近于 0，但受限于卷积核大小，实际维数不能趋向无限，离散的 sinc 函数由于使用矩形窗进行上采样，会在边界表现出抖动，为了消除这一影响，引入如式(3-13)的凯泽窗^[87]替代矩形窗。

$$KS_n = I_0 \beta \sqrt{1 - (2(n - N/2)/N)^2} \quad (3-13)$$

其中： I_0 为 0 阶贝塞尔函数^[88]； β 为凯泽窗函数主瓣宽度，根据图像特征调整； N 用于调整凯泽窗的宽度，大小与上采样卷积核尺寸一致。

为了验证改进过的上采样方法的高频抑制效果，建立如图 3-8(c)模拟 256×256 光学吸收系数测试图像。图像下采样至 128×128 作为上采样计算层的输入，分别使用双线性上采样和 sinc 窗函数上采样测试，结果如图 3-8(d)与 3-8(e)所示。 sinc 窗函数重建后的时域图像与原始测试图像的 $PSNR$ 为 23.8294 dB，双线性上采样的 $PSNR$ 为 27.1657 dB，两种方法重建图像的结构信息基本一致； sinc 窗函数重建图像的频谱信息表现出显著的高频抑制特性，并且可以通过调整凯泽窗主瓣宽度调整高频抑制范围。双线性上采样除了边缘极少数高频信息存在抑制之外，基本没有改变频谱的结构特性。




图 3-8 sinc 窗函数插值特征：(a)二维 sinc 权重结构；(b)凯泽窗函数；(c)低分辨率待插值图像；(d)双线性上采样的频域特征；(e) sinc 窗函数上采样的频域特征。

在特征提取方面，为增强模型的跨像素拟合效果，在 LYP-Net 模型中添加全局自相关网络层。本文设计一种相对轻量的多通道混洗自注意力计算层（Shuffle Selective Kernel Self-Attention, SSK），使用选择性内核自注意力，获取特征图针对宽高维度的全局感受野^[70]，并在计算层间引入通道混洗操作，提高特征图针对通道特征的层间适应能力，用以拟合复杂生物模型。

SSK 模块的结构如图 3-9 所示，其处理流程首先通过双通路并行机制实现特征提取，输入特征图在残差通路中使用 1×1 卷积核提取跨层跳连接特征，保留初始空间特征。同时，在注意力通路中先采用 3×3 与 5×5 异构卷积核进行多尺度特征提取，再使用通道混洗操作将特征图在通道维度分组卷积并随机重组，增强特征交互。接着，对通道混洗后的特征进行宽高维度的全局平均池化，压缩空间维度，提取全局特征依赖关系，并通过密集连接层为通道注意力权重矩阵筛选有效特征，将有效的全局通道特征与多尺度特征在通道维度选择性融合。最后，将 1×1 跳连接特征、 3×3 特征与 5×5 特征在通道维度进行特征匹配，利用可学习的动态特征选择机制完成多尺度信息的自适应融合，实现针对空间-通道多尺度感知信息的复合特征提取。




图 3-9 通道混洗选择性内核 SSK 结构图。

改进后的 LYP-Net 单个计算块结构如图 3-10 所示，特征输入后先使用 *Sinc* 窗函数上采样扩充图像尺寸，再使用 *AdaIN* 混合上采样前后的特征矩阵，混合结果输入卷积激活层和残差计算层提取简单特征，最后将特征图输入 SSK 计算层，提取不同尺度的全局特征，得到计算块的特征图输出。输出结果作为下一级计算块的特征输入，逐步将 $8\times 8\times 256$ 的各向同性白噪声恢复到 $256\times 256\times 1$ 的预测图像。




图 3-10 改进后的 LYP-Net 单个计算块结构。

进行消融实验验证上述对 LYP-Net 改进措施的有效性,设计包含异质性区域的理想吸收系数仿体 μ_a , 通过足量光子蒙特卡洛模拟 (总光子数 $1.2e^9$) 得到模拟声压 P_{0_T} , 并将其作为 LYP-Net 的输入。实验结果如表 3-1 所示。

在消融实验设计中,针对 AdaIN 模块的无参数特性及 Sinc 窗函数上采样的参数冻结特点,采取差异化处理策略:对于无可训练参数的 AdaIN 模块,通过剥离其特征融合功能直接传递原始激活值;而初始化即冻结参数的 Sinc 转置卷积模块,则采用保持参数维度一致的双线性上采样替代其频域约束上采样机制。这种定制化消融方案规避了传统权重冻结法的适配性问题,确保模块功能启闭的严格隔离,前者通过算法流程解耦实现特征交互消除,后者通过算子替换维持网络拓扑结构稳定性,从而精确量化各组件对模型性能的独立贡献度。

表 3-1 LYP-Net 的消融实验结果

组别	AdaIN	Sinc	SSK	RMSE(pix)	SSIM(pix)	PSNR(dB)
1	✓	✓	✓	0.0091	0.9881	42.681
2	✓	✓	-	0.0124	0.9786	40.044
3	✓	-	✓	0.0159	0.9707	38.042
4	-	✓	✓	0.0105	0.9841	41.582
5	-	-	✓	0.0349	0.9453	30.075
6	-	✓	-	0.0235	0.9567	34.292
7	✓	-	-	0.0348	0.9426	30.106
8	-	-	-	0.0678	0.9189	23.369

对比表 3-1 各组消融实验的结果:从组别 8 到组别 1 评价指标逐步提高,说明各个模块对的拟合性能都具有积极作用。AdaIN 提升模型的拟合速度, Sinc 窗函数上采样限制频谱特征, SSK 模块提高特征提取能力, 模块之间协同互补,使模型在更短的时间内到达收敛状态,有效增加了 LYP-Net 频谱偏移特征的稳定性与鲁棒性。

3.2.3 频谱对齐优化策略

为了改善 MC 模拟耗时长的的问题,提升 SS-QPAT 的迭代效率,利用 LYP-Net 迭代的频域特性与欠光子 MC 模拟的频域特性,发展出“频谱对齐”迭代策略:在 SS-QPAT 迭代的初始阶段,LYP-Net 优先拟合低频结构信息,此时对于 MC 模拟来说只需要少量光子数就可以拟合低频信息,随着迭代次数增加,LYP-Net 逐步拟合高频信息,同步增加 MC 模拟的光子数量获取有效的高频信息。在不影响重建精度的前提下,大幅度减少 SS-QPAT 重建过程中的无效光子消耗,提高模型的重建速度。

进一步地,使用消融实验中理想条件下重建的 $P_{0,T}$ 与 μ_a 作为改进的 LYP-Net 与欠光子 MC 模拟的测试数据。图 3-11(a)表示 LYP-Net 在拟合单张图像时,不同迭代轮次的时频拟合抽样;图 3-11(c)表示相同测试数据下,欠光子 MC 模拟不同光子的时频拟合抽样。将 LYP-Net 不同迭代重建的频谱信息与理想重建图像的频谱计算误差,并将 MC 模拟随光子数增加得到的频谱信息与充足光子数 MC 模拟结果的频谱信息计算误差,转换为一维频谱后的频谱误差图如图 3-11(b)所示。两类模型频谱误差的平均 PSNR 为 20.184 dB, RMSE 为 0.0979, SSIM 为 0.9023,分布趋势基本一致。SS-QPAT 利用此特性,使 MC 模拟随 LYP-Net 迭代轮次调整光子数。




图 3-11 SS-QPAT 频域特性: (a)LYP-Net 频域特性; (b)频谱误差; (c)欠光子 MC 频域特性。

“频谱对齐”训练策略如图 3-12(a)所示。通过 LYP-Net 拟合图像的一维平均频谱误差,与欠光子 MC 模拟不同光子数的一维平均频谱误差,给出 LYP-Net 不同迭代轮次对应 MC 模拟消耗的光子数 (LYP-Net 的频域阈值 0.25, 欠光子 MC 频域阈值 0.35)。改进后生成图像的时间对比如图 3-12(b)所示,相对于未对齐时 (原策略平均耗费 22.86 小时,“频谱对齐”策略平均耗费 0.447 小时),使

用该策略的重建耗时压缩了 51.141 倍，大大提高重建效率。图像重建精度对比如图 3-12(c)所示，原策略与“频谱对齐”的 RMSE 分别为 0.129 和 0.128，SSIM 分别为 0.815 和 0.822，PSNR 分别为 17.74 和 17.81，优化 MC 模拟光子数的“频谱对齐”方法没有表现出明显的指标下降，能够达到原迭代策略的重建精度。




图 3-12 SS-QPAT 频域对齐策略：(a)光子数设定策略；(b)耗时对比；(c)性能对比。

3.3 模型性能验证与跨域缺陷数据对比

设计模拟仿体、模拟小鼠、模拟组织等跨域数据集，验证 SS-QPAT 模型的低数据依赖性。通过对比 SS-QPAT 与基于数据驱动 QPAT 模型的差异，证明 SS-QPAT 在不同复杂数据中表现出高泛化性。

3.3.1 基于数据驱动深度学习模型




图 3-13 U-Net 数据驱动深度学习模型。

使用基于数据驱动深度学习模型求解 QPAT 光学逆问题时，主要使用以 U-Net 为主的深度学习模型。U-Net 包含特征采集的下采样部分和特征融合的上采样部分，通过层间连接完成不同尺度的特征融合，广泛用于医学图像的目标检测、语义分割任务，发展出如图 3-13 所示的改进后的 U-Net 模型，具体改进措施有：添加密集连接（绿色部分）、使用循环残差替换传统残差（蓝色部分）、使用自注意力提高全局参数相关性（紫色部分）等模块。本节将使用调整输入输出通道的 U-Net 模型与 SS-QPAT 模型进行跨域数值模拟验证，证明 SS-QPAT 模型不受数据分布干扰的泛化性。

3.3.2 跨域缺陷数据集

本章设计如图 3-14 所示的模拟仿体、模拟小鼠、模拟组织跨域分布数据集，用来验证 SS-QPAT 相较于传统端到端 QPAT 模型具备更强的数据泛化性能。模拟仿体为圆柱形外廓，内部包含多个不均匀吸收体，吸收系数随机在 0.01 至 0.05 mm^{-1} 设置，散射系数设置为 1 mm^{-1} （各向异性参数 0.9 ）；模拟小鼠数据集以数字鼠二维切面数据为主，包含骨骼、肌肉、脏器、血管等主要组织，吸收系数在 0.01 至 0.07 mm^{-1} 随机分布。模拟组织数据主要由科林脑和躯干 MRI 扫描数据切片组成，包括骨骼、肌肉、灰质、白质、血管等组织，吸收系数在 0.02 至 0.08 mm^{-1} 随机分布。



图 3-14 跨域缺陷数据集。

不同类别切片数据均按照图 3-5(a)的方式向 Z 轴扩展，在中心切面创建闭合宽场照明光源。为降低其他光学参数的影响，MC 模拟中，将各向异性参数与折射率设为定值。使用随机裁切和随机旋转平衡数据集图像数量，制备 2280 组模拟仿体训练样本，2548 组模拟小鼠训练样本，2494 组模拟组织训练样本。

为了定量表示数据集之间的分布差异，保证模型在跨域数上重建，本节采用评价生成模型图像相似程度的弗雷歇距离（Fréchet Inception Distance, FID）作为数据集之间的距离评价指标^[89]，FID 计算方法如式(3-14)所示：

$$FID(X, Y) = \|\mu_X - \mu_Y\|^2 + Tr(Cov_X + Cov_Y + 2(Cov_X \cdot Cov_Y)^2) \quad (3-14)$$

其中： μ_X 和 μ_Y 表示数据的均值， Cov_X 和 Cov_Y 表示数据的协方差矩阵， Tr 表示矩阵的迹。FID 的计算结果越小，表示模型生成的图像越接近于真实数据分布。遍历两类数据集，得到数据集之间的距离关系如表 3-2 所示，仿体与组织数据之间的平均 FID 为 49.514，组织与小鼠数据之间的平均 FID 为 33.983，仿体与小鼠数据之间的平均 FID 为 75.243，由于数据集之间的 FID 均大于 10，能够保证数据集之间具有明显差异。

表 3-2 数据集距离关系表

数据集	FID
模拟仿体-模拟组织	49.514
模拟仿体-模拟小鼠	75.243
模拟组织-模拟小鼠	33.983

3.3.3 跨域数值模拟验证

U-Net 模型在 3.2.2 节设计的 3 类跨域缺陷数据集上分别训练。训练集均进行 256×256 缩放与标准化预处理，训练集、验证集、测试集的比例均设置为 8:1:1。

U-Net 模型在 3 类数据集上，以相同训练参数迭代 100 轮次，得到仿体模型、组织模型、小鼠模型。将三类模型分别在仿体测试集、组织测试集、小鼠测试集上测试指标，最终测试结果如表 3-3 所示。

表 3-3 端到端模型跨域数据测试结果

训练集	测试集	仿体数据		组织数据		小鼠数据	
	指标	均值	标准差	均值	标准差	均值	标准差
仿体模型	SSIM	0.9902	0.0093	0.5114	0.1155	0.5366	0.0933
	PSNR	40.314	10.116	15.955	4.7488	16.347	6.0470
	RMSE	0.0011	0.0018	0.0413	0.0360	0.0509	0.0618
组织模型	SSIM	0.6778	0.0116	0.8378	0.0957	0.7781	0.1282
	PSNR	12.410	0.6796	25.033	10.528	15.034	5.2958
	RMSE	0.0581	0.0086	0.0208	0.0354	0.0570	0.0631
小鼠模型	SSIM	0.4921	0.0206	0.5819	0.1743	0.8257	0.0209
	PSNR	5.8193	0.1905	10.7673	5.4623	26.829	5.2241
	RMSE	0.2621	0.0116	0.1390	0.0957	0.0045	0.0066

测试结果中，同类数据训练和测试的结果（仿体模型测试仿体数据、组织模型测试组织数据、小鼠模型测试小鼠数据），仿体模型的平均 SSIM 为 0.9902，组织模型的平均 SSIM 为 0.8378，小鼠模型的平均 SSIM 为 0.8378，均在 0.8 以上，且三类模型的平均 PSNR 普遍在 20 dB 以上，测试结果的结构、亮度和对比

度均与目标值具有较高的一致性，图像差异较小；其他测试结果的平均 SSIM 普遍在 0.5 左右波动，平均 PSNR 均未超过 20 dB，预测图像与目标图像具有明显的失真，U-Net 虽然能保留主要结构信息，但无法完成细节信息精确重建。

与 U-Net 模型对应，使用 SS-QPAT 进行如上文数据驱动模型的跨数据测试，由于 SS-QPAT 属于自监督模型，在迭代过程中不会划分各类训练集的训练情况，最终各类测试集的重建结果如表 3-4 所示，平均 SSIM 分别为 0.9049、0.8187、0.8618，平均 PSNR 分别为 26.321、25.224、21.375，两类模型的评估指标的数值结果有一定波动，但 SS-QPAT 的平均 SSIM 均保持在 0.8 以上，平均 PSNR 均保持在 20 dB 以上，能够证明重建光学参数分布的结构和细节信息与目标光学参数分布足够接近；相较数据驱动模型的跨模型验证，SS-QPAT 的结果与传统数据驱动的深度学习模型表现出了显著性差异，这类差别在仿体数据集中表现得更为明显。推测其机理为：仿体数据的几何结构相比于模拟组织与模拟小鼠的切面数据较为规律，更难以代表光学逆问题的全局数据分布，尽管增加不同分布的数据能够弥补这种差异，但直接增加数据集会导致训练时间上升，也会导致模型需要更多通道数才能与数据集匹配。经过跨域数据验证，SS-QPAT 的通用性相比于数据驱动 QPAT 模型得到了显著提升，具有更强的数据适应性和抗干扰能力，能够成为解决逆向光学过程的有效工具。

表 3-4 SS-QPAT 跨域数据测试结果

测试集 指标	仿体数据		组织数据		小鼠数据	
	均值	标准差	均值	标准差	均值	标准差
SSIM	0.9049	0.0182	0.8187	0.0664	0.8618	0.0947
PSNR	26.321	2.1670	25.224	3.6065	17.375	4.5636
RMSE	0.0006	0.0002	0.0018	0.0004	0.0043	0.0016

3.4 本章小结

本章设计了一种融合先验模型方法与数据驱动方法的 SS-QPAT 自监督模型，模型结合了 MC 模拟与 LYP-Net，实现无需数据驱动的光学参数定量重建。验证可行性后，利用 LYP-Net 的频谱偏移特性和欠光子 MC 模拟的频域特性，改进 LYP-Net 模型结构，提出“频域对齐”迭代策略，在不影响重建精度的前提下，减少迭代初始阶段的光子数，降低 MC 模拟时间，将 SS-QPAT 重建速度提升了 51.1 倍。最后建立具有显著分布差异的跨域数据集，验证 SS-QPAT 模型的低数据依赖性，证明 SS-QPAT 模型广泛适用于各种复杂生物功能性成像任务。

第4章 自监督深度学习定量光声成像实验验证

在上一章节中，基于仿真数据验证了 SS-QPAT 模型的架构设计合理性，然而其在实际复杂生物组织中的适用性仍需通过实验验证。本章通过 PAT 实验系统对 SS-QPAT 模型的光学参数定量重建能力进行多维评估：首先构建“硬件-算法”协同校正机制，利用课题组自主搭建的 PAT 实验系统获取实验数据，并通过 SEED-Net 网络进行系统级误差补偿。进而基于标准化仿体实验，验证 SS-QPAT 的定量重建精度，设计含异质结构的“琼脂-脂肪乳-印度墨汁”仿体，结合 PAT 系统实验数据与 SS-QPAT 算法完成吸收系数重建。最终开展生物实验验证，成像的对象包括离体组织及在体动物。实验结果表明，SS-QPAT 能够完成对实验数据的高分辨定量重建，具备临床转化潜力。

4.1 PAT 实验系统与误差校正

使用课题组搭建的 PAT 实验系统完成光声信号采集与反投影声学重建，但是受到系统误差的影响，重建的光声图像与理想图像之间有一定的差异，为了避免系统误差对 SS-QPAT 重建性能的干扰，设计了一种非对称式风格迁移模型 SEED-Net 完成系统误差校正。

4.1.1 PAT 实验系统

采用如图 4-1 所示的 PAT 实验系统采集实验数据，实验系统由以下几部分构成：Nd:YAG 激光器、近红外波段光学参量振荡器（Optical Parametric Oscillator, OPO）、整形光路、超声换能器、采集控制系统。

Nd:YAG 激光器的输出波长 532 nm，重频 10 Hz，脉冲宽度 6 ns，此激光的脉宽满足产生光声信号的绝热膨胀条件。由于血红蛋白、脂质的吸收峰位于近红外波段，而激光器输出的波长位于背景和组织吸收没有显著差异的可见光波段，需要使用 OPO 调整激光器输出的波段，将激光波长选择性调谐至 680 nm~1064 nm（仿体和生物实验设定为 710 nm），输出 60 mJ 的近红外脉冲激光。OPO 输出的激光经柱状透镜组整形、伽利略式透镜组缩束后，调整为直径为 4 mm 的圆形光斑，通过经四臂光纤束将光束均匀引导至超声聚焦面，激光在超声聚焦面外侧向聚焦中心均匀辐射。使用超声换能器接收组织体经短脉冲激发产生的光声信号，换能器为中心频率 3.5 MHz，焦距 76 mm，表面直径 25 mm 的柱聚焦换能

器，实际聚焦宽度 1.3 mm，聚焦长度约 28 mm，聚焦范围能满足实际需求。信号经过前置放大器(PREAMP2-D, US-Ultratek)输入至高速数据采集卡(PCI8552)中，采集卡的采样频率最高为 150 MHz，满足奈奎斯特采样定理。使用电机控制器(Zolix-SC300)控制系统 42 步进电机，旋转步进间距设为 1° ，通过逐角度采集的方式完成光声信号采集。

使用 LabVIEW 上位机控制硬件系统，完成激光器与采集卡的信号同步并完成采集卡与电机控制器的逐角度循环采集。换能器聚焦中心与电机的旋转中心重合，每角度进行 5 次重复采集取均值，作为该角度的光声信号，最终得到 360×8000 的逐角度的光声数据。逐角度光声数据使用滤波反投影算法，完成 PAT 系统成像切面的信号重建，获得实验域初始声压图像。




图 4-1 实验系统结构图。

4.1.2 系统误差校正网络

在 PAT 实验系统中，存在各种干扰因素如：温度、换能器偏差、放大器干扰、激光器能量强度差异等。多种因素非线性耦合构成了测量系统的系统误差，随着测量值的变化产生复杂的随机扰动，影响光声图像的质量。然而光声图像的质量直接影响 SS-QPAT 模型的重建效果，为了准确评估 SS-QPAT 的成像性能，需要对系统误差进行补偿。因为系统误差随着测量值变化而呈复杂规律变化，传统方法对此误差的校正效果不佳，所以引入一种非对称参数对齐网络 SEED-Net，消除系统误差的影响^[90]。

SEED-Net 网络结构如图 4-2 所示：生成器的输入为 $1 \times 256 \times 256$ 的图像，先通过前置卷积层提升通道数，再通过多个残差卷积层提取不同维度的特征，最后输出尺寸为 $1 \times 256 \times 256$ 的预测图像；鉴别器以生成器的输出作为输入，经过计算层多次特征提取，逐步压缩特征矩阵维度，得到 $64 \times 30 \times 30$ 的特征矩阵。




图 4-2 SEED-Net 模型结构。

SEED-Net 的计算流程如图 4-3 所示：其中 G_e 、 G_s 代表图 4-2 所示的生成器， D_e 、 D_s 代表图 4-2 所示的鉴别器， org_s 表示理想模拟图像， org_e 表示实验重建图像，理想图像通过 G_e 生成实验图像，实验图像通过 G_s 生成理想图像， D_e 用于判断图像是否为 G_e 生成的图像， D_s 用于判断图像是否为 G_s 生成的图像。训练过程中， org_s 和 org_e 通过 G_e 与 G_s 生成转换风格的生成图像 gen_e 和 gen_s ，生成图像 gen_e 和 gen_s 通过 G_s 与 G_e 生成与 org_s 和 org_e 对应的一致性图像 rec_s 和 rec_e 。

损失计算过程中，包括生成鉴别损失： $D\text{-Loss} = \argmin_{D_x} [D_x(org_x) - mat_{01}]$ ， $G\text{-Loss} = \argmin_{G_x} [D_x(G_x(org_x)) - mat_{01}]$ ，以及判断风格转换的循环一致性损失 $Cycle\text{-Loss} = \argmin_{G_x, G_y} [G_y(G_x(org_x)) - X]$ ， $Idt\text{-Loss} = \argmin_{G_x} [G_x(org_y) - Y]$ 。SEED-Net 不会直接使用生成图像 gen_e 和 gen_s 计算损失函数，而是通过上述损失间接计算，因此，在梯度传播时可以使用不一一对应的训练数据。可以使用足量不同分布的数据作为 SEED-Net 的训练集。且实验数据与模拟数据之间的 FID 足够接近，风格转换压力较低，通过非对称的模拟-实验数据训练，使 SEED-Net 学习足量特征以消除 PAT 实验系统的系统误差。




图 4-3 SEED-Net 参数迭代流程。

4.2 仿体模型验证

本节通过制备已知光学异质区域的“琼脂-脂肪乳-印度墨汁”仿体，进行仿

体实验验证。经过 PAT 系统采集与 SEED-Net 系统误差校正，得到理想的初始声压数据，并将其作为 SS-QPAT 的输入，进行光学参数的定量重建。定量分析系统误差校正后的实验数据在 SS-QPAT 上的定量重建精度，证明 SS-QPAT 具有高分辨率定量重建能力。

4.2.1 仿体设计与制作

制备具有不同光学吸收参数分布的仿体模型，验证 SS-QPAT 模型对光学吸收异质区域定量重建能力。设计如图 4-4(a)所示三维仿体模型，完成实验仿体异质区域划分，再使用 ABS 树脂材料 3D 打印如图 4-4(b)所示的仿体模具，模具内部包含空腔，模拟不同光学吸收系数的异质区域，空腔结构包括 3.3 节仿体数据的几何柱状结构，也包括模拟肝肾外观、小鼠切面外观、小鼠脑部切面的近似结构，更符合实际复杂生物组织的结构信息。模具打印误差在 $\pm 200 \mu\text{m}$ 内，满足 PAT 实验系统的成像需要。各模具直径为 25 mm，将尺寸限制在成像聚焦平面内。




图 4-4 仿体模具与三维模型：(a)三维模型；(b)仿体模具模型。

打印仿体模具后，制备包含光学异质吸收的仿体模型：使用不会对近红外短脉冲激光产生吸收与散射的琼脂作为模型的固定基底，并使用印度墨汁（Indian Ink）和 20%脂肪乳注射液配置仿体异质区域的光学吸收和散射系数。预先制备较高浓度的印度墨汁母液，使用紫外分光光度计（UV-2550）测定母液在近红外波段的吸光度，并将母液按照比例稀释，得到具有特定吸收系数的印度墨汁溶液。稀释后的溶液与琼脂粉末按照 2.8 g:100 ml 的配比混合，并加热去除气泡，待冷却后为溶液补充脂肪乳注射液。通过转子搅拌器混匀浇筑到图 4-4(b)的仿体模具异质区域，进一步降温冷却凝固，倒模并浇筑背景区域的琼脂溶液，待背景区域的琼脂溶液冷却凝固后，得到“琼脂-脂肪乳-印度墨汁”仿体。为了与生物组织的光学系数一致，仿体背景吸收系数设置为 0.01 mm^{-1} ，各异质区域吸收系数随机设置在 0.02 mm^{-1} 至 0.05 mm^{-1} 区间内，仿体的散射系数设置为 10 cm^{-1} 。

共设计 18 个仿体模型，每个仿体模型在 PAT 实验系统中获取切面光声信号分布，反投影重建得到实验数据，实验数据与相对应的模拟数据同步进行随机裁切旋转扩充数据集，最终得到 3240 组配对数据用于后续验证。

4.2.2 仿体实验结果

首先利用 SEED-Net 校正系统误差，如图 4-5(a)所示，经过非对称训练，将实验重建图像，转换为消除系统误差的生成图像。训练数据、测试数据、生成数据的数据分布直方图如图 4-5(b)所示，经过 SEED-Net 生成的图像数据分布，基本与原有训练集与测试集的数据分布保持一致，能够减少 PAT 实验系统的系统误差，获取更高质量的重建图像。




图 4-5 SEED-Net 性能验证：(a)训练/测试/生成图像示例；(b)图像数据分布。

将校正后的声压分布 P_{exp} 与在仿真域上建立的模拟声压分布 P_{sim} 输入 SS-QPAT 进行迭代重建，获得的光学吸收系数重建结果如图 4-6 所示。其中，图 4-6(a)为吸收系数分布的真值 μ_a^{GT} ，图 4-6(b)为基于该分布制作的光学异质吸收仿体模型；图 4-6(c)为未经校正系统误差的声压分布 P_{org} ，图 4-6(d)为校正后的声压分布 P_{exp} ；图 4-6(e)为 P_{exp} 经 SS-QPAT 重建的吸收系数分布 μ_a^{exp} ，图 4-6(f)为

P_{sim} 经 SS-QPAT 重建的吸收系数分布 μ_a^{sim} 。




图 4-6 仿体实验结果：(a)吸收系数分布真实值；(b)光学异质吸收仿体模型；(c)校正前声压；(d)校正后声压；(e)实验域重建吸收系数分布；(f)仿真域重建吸收系数分布。

对上述结果（共计 324 组）进行定量分析，如表 4-1 所示。定量分析结果表明：在仿真域中，重建值 μ_a^{sim} 与真值 μ_a^{GT} 的平均 RMSE 为 0.0402、平均 PSNR 为 28.023dB、平均 SSIM 为 0.9852；在实验域中，重建值 μ_a^{exp} 与真值 μ_a^{GT} 的平均 RMSE 为 0.0684、平均 PSNR 为 23.862 dB、平均 SSIM 为 0.9565。尽管实验环境下指标值存在约 41.3% 的相对降幅（以 RMSE 计），但关键参数仍稳定维持在 RMSE<0.1、PSNR>20 dB、SSIM>0.95 的阈值内，证明模型在真实场景中的基础可靠性。

表 4-1 异质体仿体指标

类别	RMSE	PSNR	SSIM
μ_a^{sim}	0.0402	28.023	0.9852
μ_a^{exp}	0.0684	23.862	0.9565

图 4-6(e)与图 4-6(f)的对比显示，仿真重建 μ_a^{sim} 与实验重建 μ_a^{exp} 的吸收系数分布呈现高度相似的空间结构，二者的 SSIM 达 0.9645。在异质体边界区域（图 4-7），尽管实验重建在 0.05 mm^{-1} 的高吸收区存在约 0.0885 的 RMSE 值（表 4-2），其抽样曲线仍能准确跟踪真值 μ_a^{GT} 的突变趋势，仅出现可接受的边缘平滑现象，且低吸收区的指标差异较小。证明了本网络在仿真环境与真实场景中表现出

一致性，这种跨域一致性特征表明：网络的物理驱动架构能够在不同数据域中保持稳定的特征提取能力。




图 4-7 仿体实验抽样曲线。

表 4-2 异质体仿体边界指标

类别	$\mu_a(\text{mm}^{-1})$	0.01	0.02	0.03	0.04	0.05
μ_a^{sim}	RMSE	0.0412	0.0502	0.0833	0.0553	0.0154
	PSNR	27.696	26.007	22.488	25.173	26.496
μ_a^{exp}	RMSE	0.0490	0.0661	0.1157	0.0988	0.0885
	PSNR	26.246	24.212	19.326	20.570	21.309

4.3 离体组织与在体动物的自监督定量光声重建

仿体实验验证了 SS-QPAT 模型在误差校正实验数据上的定量重建效果，而复杂生物组织与仿体模型有一定差异，还需要进一步测试 SS-QPAT 模型在生物组织中的重建能力。本节利用家兔内脏等生物离体组织，完成生物离体组织重建验证。进一步使用实验小鼠在 PAT 系统中完成活体动物的光学参数定量重建，验证 SS-QPAT 对活体动物的高精度光学参数定量重建能力，在不依赖数据集的情况下完成基于深度学习的自监督光学参数定量重建。

4.3.1 离体组织定量光声重建

完成 SS-QPAT 模型的仿体实验验证后, 测试 SS-QPAT 在离体生物组织上的光学参数定量重建效果。由于 55 °C 以上会导致生物组织蛋白质变性, 因此本节使用低温琼脂配置仿体, 防止离体组织受热变性影响组织体光学特性。使用没有异质空腔的仿体模具外壳, 配置无吸收散射的琼脂溶液作为离体组织的固定基底。取 2.2~2.4 Kg 的 4 月龄新西兰兔, 使用 2% 异氟烷气体麻醉与 10% 水合氯醛溶液 100 g/0.5 ml 深度麻醉, 随后进行安乐死, 取心脏与肾脏组织置入 4% 多聚甲醛溶液中保持结构; 加热低温琼脂溶液去除气泡, 并通过转子搅拌器冷却至 45 °C, 最终制备生物组织离体模型如图 4-8(a) 所示。离体组织模型在 PAT 成像系统中逐角度采集光声信号, 重建得到实验重建声压分布 P_{org} 如图 4-8(b) 所示, 经过 SEED-Net 校正系统误差得到的重建声压分布 P_{exp} 如图 4-8(c) 所示。最后使用 SS-QPAT 模型对 P_{exp} 迭代重建, 得到如图 4-8(d) 所示的吸收系数分布 μ_a^{exp} 。




图 4-8 生物离体组织光学参数定量重建: (a)实验兔离体组织模型; (b)实验初始声压分布; (c)校正初始声压分布; (d)实验重建吸收系数分布。

通过 SS-QPAT 重建结果可以看出, 经过定量光学反演得到的 μ_a^{exp} 相比于 P_{org} , 对组织体的血供与结构信息更为敏感, 不会因光子传播导致深层组织结构模糊, 更符合实际生物组织的光学参数分布规律, 能够定量反映组织体的光学特征。

4.3.2 在体动物定量光声重建

由于离体组织从取样到模型制备耗时较长, 导致离体组织内部的含氧血红蛋白含量相比在体组织有所下降, 光学参数与理想在体组织有一定差异, 为了进一步探究 SS-QPAT 模型在活体生物组织上的光学定量重建能力, 本节进一步使用

活体小动物进行在体动物的定量光声重建实验。

本文取 SPF 级 4 周龄雄性昆明小鼠建立活体动物在体模型，使用 2.5% 三溴乙醇按照 10 g/0.2 ml 的配比为小鼠浅度麻醉，使用脱毛膏去除毛发，将小鼠按照如图 4-9(a)所示的方式固定，置于 PAT 系统的成像聚焦面内，为防止小鼠在实验时苏醒，在信号采集过程中使用 2% 异氟烷气体麻醉防止麻醉失效。采集多个断层截面得到如图 4-9(b)所示的实验重建声压分布 P_{org} ，后经过 SS-QPAT 重建反演得到图 4-9(d)的在体模型吸收系数分布 μ_a^{exp} 。

相比于声学重建的 P_{org} ，经过 SS-QPAT 重建的 μ_a^{exp} 对昆明小鼠组织体内高光学吸收特性的腹主动脉等器官具有更加敏感的特征能力，对光学细节特征的表现更加敏感。后期可通过图像的结构特征，确定 μ_a^{exp} 截面各类组织器官的吸收系数分布范围，完成具有绝对定量能力的光学系数重建。通过以上实验结果可以论证，本文提出的 SS-QPAT 模型有能力重建与真实生物组织光学特性一致的在体生物吸收系数分布，能够满足深层组织高分辨率的光学成像。




图 4-9 活体小鼠在体光学参数定量重建：(a)昆明鼠在体动物模型；(b)实验初始声压分布；(c)校正初始声压分布；(d)实验重建吸收系数分布。

使用 PBS 稀释后的鼠源肿瘤细胞悬液，在免疫缺陷小鼠大腿根部建立皮下鼠源肿瘤在体模型，验证 PAT 成像系统与 SS-QPAT 模型的功能性成像能力。肿瘤一周后取肿瘤小鼠，进行与在体小鼠操作过程一致的麻醉脱毛处理。为了防止腿部肿瘤超出成像聚焦面范围，将肿瘤小鼠以图 4-10(a)的方式固定，经过 PAT 系统采集重建得到实验重建声压如图 4-10(b)所示，随后使用 SS-QPAT 重建得到如图 4-10(d)所示的定量吸收系数分布。

皮下肿瘤相对于正常组织具有更强的代谢能力，肿瘤附近的血供会相比正常

组织更加明显^[91]，观测成像结果可知，4-10(b) P_{org} 与 4-10(d) μ_a^{exp} 都能够较为清晰观测到肿瘤外部的血管， μ_a^{exp} 对组织内部的血红蛋白表现出了更高的空间对比度，且因 μ_a^{exp} 克服了光通量的干扰，可以观测到更深层组织的血供分布信息，相比于传统的 PAT 成像，基于 SS-QPAT 模型的 QPAT 成像能够提供更全面的组织光学信息，在外周血管观测、早期癌症筛查、肿瘤转移预测等临床热点领域有着更为显著的优势与潜在的预临床应用前景。




图 4-10 肿瘤小鼠在体光学参数定量重建：(a)皮下肿瘤小鼠在体模型；(b)实验初始声压分布；(c)校正初始声压分布；(d)实验重建吸收系数分布。

4.4 本章小结

本章使用 PAT 系统与 SS-QPAT 模型，进行仿体模型、离体组织模型和在体生物模型的光学参数定量重建实验验证，实现从初始声压分布到光学参数分布的完整计算流程。仿体实验的结果证明了 SS-QPAT 能够使用实验数据完成高分辨率、高定量的光学吸收图像重建。离体组织模型、在体小鼠模型、在体肿瘤模型实验结果验证了 SS-QPAT 在复杂生物组织上的参数定量能力，并且在病理组织中取得了显著效果，体现其在生物医学功能性成像领域的重要应用潜力。

第 5 章 总结与展望

5.1 本文总结

PAT 是一种以光学吸收激发并以机械波形式传播信号的生物功能性影像技术，突破传统深层组织光学成像空间分辨率瓶颈，高分辨重建深层组织光学吸收特性图像，是目前预临床研究中的重要研究方向之一。PAT 借助生物组织内源性生色团或外源性靶向显影剂对光子能量的吸收转换，定量反映生物体结构与功能特征，在血管成像、血氧成像、黑色素瘤成像等生物功能性成像领域具有重要研究价值。传统 PAT 技术重建的初始声压图像是光子能量强度与光子吸收系数共同作用的结果，但随着传播路径上生色团对光能的吸收转换光子能量强度会发生非线性衰减，造成初始声压图像无法直接反映深层组织的光学吸收特性。因此，需要发展出一种光学参数定量方法解决上述深层组织图像重建问题，实现符合组织体生理病理特征的生物功能性成像。

传统基于联合成像的吸收系数定量重建方法，需要引入多个系统，会导致硬件设计复杂，多模态成像匹配困难，不利于应用推广。因此，发展出利用光学先验模型、训练非线性映射求解器等直接解决模型光学逆问题的 QPAT 技术。基于先验模型的 QPAT 方法难以兼具高空间分辨率和高定量性，随着迭代收敛过程定量精度提升的同时空间分辨率逐步降低，且迭代收敛耗时长；基于数据驱动的 QPAT 方法通过配对的训练数据实现光学求逆，提高了端到端类数据驱动模型的并行计算加速能力，但由于活体组织的光学吸收数据难以获取，导致端到端的 QPAT 模型泛化性受限。

为了突破当前 QPAT 方法的瓶颈问题，本文结合光学先验模型与数据驱动模型，提出一种自监督定量光声重建模型 SS-QPAT。为了提高模型迭代速度，提出一种降低 MC 模拟光子包数量的“频谱对齐”训练策略，将 SS-QPAT 的重建速度提升了两个数量级。对比 SS-QPAT 与基于数据驱动的 QPAT 模型在跨域缺陷数据集上的重建结果，证明 SS-QPAT 的高泛化性。仿体实验中，采用“琼脂-脂肪乳-印度墨汁”模型，验证 SS-QPAT 在 PAT 实验系统中的参数定量能力。最后，通过离体组织与在体动物实验结果，测试 SS-QPAT 在复杂生物组织中的光学参数定量重建效果。

本文工作如下：

(1) 研究背景：以功能性成像为切入点，总结 PAT 成像技术在血管成像、血氧成像、黑色素瘤成像等生物功能性成像中的重要作用。分析 PAT 成像技术进行深层组织结构成像时，因光子能量衰减导致深层组织定量精度低的问题。综述当前主要 PAT 定量重建方法，如联合成像吸收系数定量重建、基于先验模型的 QPAT 方法和基于数据驱动的 QPAT 方法等。分析当前 PAT 定量重建方法的原理与局限性，介绍本文主要工作内容。

(2) 理论基础：梳理 QPAT 涉及的光学与声学传播重建过程和深度学习理论模型。首先，描述光子在组织体内的光学吸收与散射效应，以及 RTE 方程、DA 方程、MC 模拟等 PAT 正向光学模型，阐述光学正向过程，进而说明 PAT 中光声信号扩散的声学正向过程。随后，描述与正向过程对应的逆向过程，阐述求解声学传播过程的 FBP 声学重建算法和迭代式光学求逆算法的计算流程。最后，总结深度学习的基础理论，说明卷积计算与梯度传播逻辑，简述图像生成领域的典型模型。

(3) 模型设计：首先，提出了 SS-QPAT 自监督深度学习定量光声模型框架，设计光子 MC 模拟与 LYP-Net 的整体结构，详细阐述光子 MC 模拟与 LYP-Net 的参数优化过程，概述模型的损失函数与梯度计算流程。接着，为了提高模型迭代速度提出“频谱对齐”迭代策略，即利用 LYP-Net 在迭代过程中优先拟合低频信息的频谱偏移特性，迭代前期使用少量光子进行 MC 模拟，将 SS-QPAT 的成像速度提升了 51.1 倍。最后，采用带有明显分布差异的跨域缺陷数据集，验证相比于传统数据驱动 QPAT 模型，SS-QPAT 具有更强的数据泛化能力。

(4) 实验验证：系统验证了 SS-QPAT 在生物组织光学参数定量重建中的性能优势。在仿体实验中，利用 PAT 实验系统和“琼脂-脂肪乳-印度墨汁”仿体模型，明确了 SS-QPAT 在 PAT 实验数据中的定量重建能力。为进一步评估其在真实生物场景中的适用性，创新性开展离体与在体实验研究：利用离体新西兰兔肝肾组织模型和活体昆明鼠模型，实现对正常生理状态下生物组织的高分辨率光学参数重建；借助免疫缺陷肿瘤模型，成功验证了 SS-QPAT 在病理组织中的功能性成像能力。实验结果充分表明，SS-QPAT 能够突破复杂生物组织的光学特性干扰，实现高精度、高分辨率的光学参数定量重建，为生物医学领域的功能性成像研究提供了可靠的技术方案。

5.2 工作展望

本文发展了一种 SS-QPAT 模型，在无需使用数据预训练的情况下，完成 QPAT 高分辨率光学参数逆向求解，本文提出的 SS-QPAT 模型还有进一步发展空

间，未来工作展望如下：

（1）本文模型将组织内的散射系数、各向异性参数与格日尼森因子设定为固定值，这一简化处理有效降低了模型的复杂度，但同时影响了 SS-QPAT 的定量精度，可针对现有 SS-QPAT 模型的梯度计算流程展开深度优化，探索更为精细的参数解耦策略。通过引入动态参数调整机制或改进数值计算算法，有望突破当前参数固定的限制，实现散射系数、格日尼森系数等其他关键光学参数的联合反演求解，从而构建更为完整、精准的光声成像参数模型。

（2）本文 PAT 实验系统使用传统的 FBP 重建算法进行声学参数反演，然而，受限于 FBP 算法固有的数学模型特性与离散化处理方式，其在声学参数定量反演时存在准确度瓶颈。后续研究可引入点扩散函数、MB 重建等技术进行声学重建，增加 PAT 系统重建初始声压分布信息的准确性，为 SS-QPAT 提供更可靠的声学基础数据。

（3）受限于硬件计算性能，本研究的 QPAT 实验仅基于 256×256 二维切面数据开展光学参数重建工作。当前二维数据处理模式虽能实现基础参数解析，但难以完整捕捉复杂生物组织的空间分布特性与立体光学信息。后续研究可在现有 SS-QPAT 模型框架下，引入三维空间卷积、三维 Sinc 上采样等计算层，构建更大规模的 MC 模拟，实现对复杂三维生物组织的高精度光学参数重建。

（4）本研究目前依托单一波长实现组织体的光学吸收参数重建，为了进一步获取组织体的生理功能状态信息，在后续的研究中将引入多波长光声成像技术，结合多光谱非线性解混技术，对脱氧血红蛋白、含氧血红蛋白、脂肪等目标分子进行定量重建，进一步实现生物组织的代谢状态、麻醉状态等功能性检测。

参考文献

- [1] Kumari P, Chauhan J, Bozorgpour A, et al. Continual Learning in Medical Image Analysis: A Comprehensive Review of Recent Advancements and Future Prospects[C]. 2023.
- [2] Najjar R. Redefining Radiology: A Review of Artificial Intelligence Integration in Medical Imaging[J]. *Diagnostics*, 2023, 13(17): 2760.
- [3] Cahyawijaya S. Biomedical Image Reconstruction: A Survey[J]. *arXiv*: 2301.11813, 2023.
- [4] Khashami F. A mini review of NMR and MRI[J]. *arxiv*: 2401.01389, 2024.
- [5] Xiao J H, Du Y C, Li H Q, et al. Ultrafast High Energy Electron Radiography for Electromagnetic Field Diagnosis[J]. *Journal of Instrumentation*, 2022, 17(01): P01033.
- [6] 郝素丽, 王云山, 张龙达, et al. 正电子发射断层成像空间分辨率的限制及研究进展[J]. *中国医疗器械信息*, 2022, 28(23): 43-45.
- [7] Ruan Y, Yang D, Tang Z, et al. Reference-based OCT Angiogram Super-resolution with Learnable Texture Generation[J]. *arXiv*: 2305.05835, 2023.
- [8] Huang L, Luo R, Liu X, et al. Spectral imaging with deep learning[J]. *Light: Science & Applications*, 2022, 11(1): 61.
- [9] Li L, Wang L V. Recent Advances in Photoacoustic Tomography[J]. *BME Frontiers*, 2021, 2021: 9823268.
- [10] Lai P, Nie L, Wang L. Special issue “Photoacoustic imaging: microscopy, tomography, and their recent applications in biomedicine” in visual computation for industry, biomedicine, and art[J]. *Visual Computing for Industry, Biomedicine, and Art*, 2021, 4(1): 16, s42492-021-00082-0.
- [11] 黄珊珊, 聂立铭. 光声成像在生物医学研究中的应用进展[J]. *厦门大学学报 (自然科学版)*, 2019, 58(5): 625-636.
- [12] Yao B, Zeng Y, Dai H, et al. Sparse-view Signal-domain Photoacoustic Tomography Reconstruction Method Based on Neural Representation[C]. 2024.
- [13] Guan S, Khan A A, Sikdar S, et al. Limited-View and Sparse Photoacoustic Tomography for Neuroimaging with Deep Learning[J]. *Scientific Reports*, 2020, 10(1): 8510.
- [14] Han P, Lv Y, Zhang B, et al. Enhancing eMSOT with nonlinear mixed model approaches for precise blood oxygenation imaging in tissues[J]. *APL Photonics*, 2024.

- [15] Li L, Zhu L, Ma C, et al. Single-impulse panoramic photoacoustic computed tomography of small-animal whole-body dynamics at high spatiotemporal resolution[J]. *Nature Biomedical Engineering*, 2017, 1(5): 0071.
- [16] Lin L, Hu P, Shi J, et al. Single-breath-hold photoacoustic computed tomography of the breast[J]. *Nature Communications*, 2018, 9(1): 2352.
- [17] Nagae K, Asao Y, Sudo Y, et al. Real-time 3D Photoacoustic Visualization System with a Wide Field of View for Imaging Human Limbs[J]. *F1000Res*, 2019.
- [18] Perrot V, Polichetti M, Varray F, et al. So you think you can DAS? A viewpoint on delay-and-sum beamforming[J]. *Ultrasonics*, 2021, 111: 106309.
- [19] McKeighen R E, Buchin M P. New Techniques for Dynamically Variable Electronic Delays for Real Time Ultrasonic Imaging[C]. 1977 Ultrasonics Symposium. IEEE, 1977: 250-254.
- [20] Xu M, Wang L V. Universal back-projection algorithm for photoacoustic computed tomography[J]. *Physical Review E*, 2005, 71(1): 016706.
- [21] Cox B, Laufer J G, Arridge S R, et al. Quantitative spectroscopic photoacoustic imaging: a review[J]. *Journal of Biomedical Optics*, 2012, 17(6): 061202.
- [22] Tarvainen T, Cox B. Quantitative photoacoustic tomography: modeling and inverse problems[J]. *Journal of Biomedical Optics*, 2023, 29(S1).
- [23] Yin L, Wang Q, Zhang Q, et al. Tomographic imaging of absolute optical absorption coefficient in turbid media using combined photoacoustic and diffusing light measurements[J]. *Optics Letters*, 2007, 32(17): 2556.
- [24] Bauer A Q, Nothdurft R E, Erpelding T N, et al. Quantitative photoacoustic imaging: correcting for heterogeneous light fluence distributions using diffuse optical tomography[J]. *Journal of Biomedical Optics*, 2011, 16(9): 096016.
- [25] Mahmoodkalayeh S, Zarei M, Ansari M A, et al. Improving vascular imaging with co-planar mutually guided photoacoustic and diffuse optical tomography: a simulation study[J]. *Biomedical Optics Express*, 2020, 11(8): 4333.
- [26] Zhang S, Qi L, Li X, et al. MRI Information-Based Correction and Restoration of Photoacoustic Tomography[J]. *IEEE Transactions on Medical Imaging*, 2022, 41(9): 2543-2555.
- [27] Ulrich L, Ahnen L, Akarçay H G, et al. Spectral correction for handheld optoacoustic imaging by means of near-infrared optical tomography in reflection mode[J]. *Journal of Biophotonics*, 2019, 12(1): e201800112.
- [28] Tarvainen T, Pulkkinen A, Cox B T, et al. Image reconstruction in quantitative photoacoustic tomography using the radiative transfer equation and the diffusion approximation[C]. Ntziachristos V, Lin C P. *European Conferences on Biomedical Optics*. Munich, Germany, 2013: 880006.
- [29] Bal G, Ren K. On multi-spectral quantitative photoacoustic tomography in

- diffusive regime[J]. *Inverse Problems*, 2012, 28(2): 025010.
- [30] Bal G, Ren K. Multi-source quantitative photoacoustic tomography in a diffusive regime[J]. *Inverse Problems*, 2011, 27(7): 075003.
- [31] Rabanser S, Neumann L, Haltmeier M. Stochastic Proximal Gradient Algorithms for Multi-Source Quantitative Photoacoustic Tomography[J]. *Entropy*, 2018, 20(2): 121.
- [32] Zhou X, Akhlaghi N, Wear K A, et al. Evaluation of Fluence Correction Algorithms in Multispectral Photoacoustic Imaging[J]. *Photoacoustics*, 2020, 19: 100181.
- [33] Hänninen N, Pulkkinen A, Leino A, et al. Application of diffusion approximation in quantitative photoacoustic tomography in the presence of low-scattering regions[J]. *Journal of Quantitative Spectroscopy and Radiative Transfer*, 2020, 250: 107065.
- [34] Leino A A, Lunttila T, Mozumder M, et al. Perturbation Monte Carlo Method for Quantitative Photoacoustic Tomography[J]. *IEEE Transactions on Medical Imaging*, 2020, 39(10): 2985-2995.
- [35] Hänninen N, Pulkkinen A, Arridge S, et al. Estimating absorption and scattering in quantitative photoacoustic tomography with an adaptive Monte Carlo method for light transport[J]. *Inverse Problems and Imaging*, 2024, 18(5): 1052-1077.
- [36] Lili Zhou, Jiajun Wang, Danfeng Hu. The application of dictionary based compressed sensing for photoacoustic image[C]. 2014 International Conference on Machine Learning and Cybernetics. Lanzhou, China: IEEE, 2014: 98-102.
- [37] Sahlström T, Tarvainen T. Utilizing variational autoencoders in the Bayesian inverse problem of photoacoustic tomography[J]. *SIAM Journal on Imaging Sciences*, 2023, 16(1): 89-110.
- [38] Kirchner T, Gröhl J, Maier-Hein L. Context encoding enables machine learning-based quantitative photoacoustics[J]. *Journal of Biomedical Optics*, 2018, 23(05): 1.
- [39] Yang C, Lan H, Gao F, et al. Review of deep learning for photoacoustic imaging[J]. *Photoacoustics*, 2021, 21: 100215.
- [40] Dehner C, Zahnd G, Ntziachristos V, et al. A deep neural network for real-time optoacoustic image reconstruction with adjustable speed of sound[J]. *Nature Machine Intelligence*, 2023, 5(10): 1130-1141.
- [41] Chen T, Lu T, Song S, et al. A deep learning method based on U-Net for quantitative photoacoustic imaging[C]. Oraevsky A A, Wang L V. *Photons Plus Ultrasound: Imaging and Sensing 2020*. San Francisco, United States: SPIE, 2020: 137.
- [42] Li J, Wang C, Chen T, et al. Deep learning-based quantitative optoacoustic

- tomography of deep tissues in the absence of labeled experimental data[J]. *Optica*, 2022, 9(1): 32.
- [43] Yao J, Wang L V. Sensitivity of photoacoustic microscopy[J]. *Photoacoustics*, 2014, 2(2): 87-101.
- [44] Zhang K, Chen F, Wang L, et al. Second Near-Infrared (NIR-II) Window for Imaging-Navigated Modulation of Brain Structure and Function[J]. *Small*, 2023, 19(14): 2206044.
- [45] Hong G, Diao S, Antaris A L, et al. Carbon Nanomaterials for Biological Imaging and Nanomedicinal Therapy[J]. *Chemical Reviews*, 2015, 115(19): 10816-10906.
- [46] Choi W, Park B, Choi S, et al. Recent Advances in Contrast-Enhanced Photoacoustic Imaging: Overcoming the Physical and Practical Challenges[J]. *Chemical Reviews*, 2023, 123(11): 7379-7419.
- [47] 戴丽娟, 花国然, 钱志余. 脑组织漫反射光谱与约化散射系数的斜率估算法[J]. *光学技术*, 2010, 36(05): 705-709.
- [48] Matcher S J, Cope M, Delpy D T. In vivo measurements of the wavelength dependence of tissue-scattering coefficients between 760 and 900 nm measured with time-resolved spectroscopy[J]. *Applied Optics*, 1997, 36(1): 386.
- [49] Arridge S R. Optical tomography in medical imaging[J]. *Inverse Problems*, 1999, 15(2): R41-R93.
- [50] Joseph J H, Wiscombe W J, Weinman J A. The delta-Eddington approximation for radiative flux transfer[J]. *J.atmos*, 1976, 33(12).
- [51] Wang L. MCML - Monte Carlo modeling of light transport in multi-layered tissues [J]. *Computer Methods and Programs in Biomedicine*, 1995. 47(2): 131-146
- [52] Vorba J, Křivánek J. Adjoint-driven Russian roulette and splitting in light transport simulation[J]. *ACM Transactions on Graphics*, 2016, 35(4): 1-11.
- [53] Lu T, Li J, Chen T, et al. Parallelized Monte Carlo Photon Transport Simulations for Arbitrary Multi-Angle Wide-Field Illumination in Optoacoustic Imaging[J]. *Frontiers in Physics*, 2020, 8: 283.
- [54] Fang Q. Mesh-based Monte Carlo method using fast ray-tracing in Plücker coordinates[J]. *Biomedical Optics Express*, 2010, 1(1): 165.
- [55] Fang Q. Comment on “A study on tetrahedron-based inhomogeneous Monte-Carlo optical simulation”[J]. *Biomedical Optics Express*, 2011, 2(5): 1258.
- [56] Xu M, Wang L V. Universal back-projection algorithm for photoacoustic computed tomography[C]. Oraevsky A A, Wang L V. *Biomedical Optics 2005*. San Jose, CA, 2005: 251.
- [57] Zhang W, Li G, Xue L. Profile inference on partially linear varying-coefficient errors-in-variables models under restricted condition[J]. *Computational Statistics & Data Analysis*, 2011, 55(11): 3027-3040.

- [58] Duchi J, Hazan E, Singer Y. Adaptive Subgradient Methods for Online Learning and Stochastic Optimization[J].
- [59] Tang K, Zhang S, Wang Y, et al. Learning spatially variant degradation for unsupervised blind photoacoustic tomography image restoration[J]. *Photoacoustics*, 2023, 32: 100536.
- [60] Werbos P J. Beyond Regression : "New Tools for Prediction and Analysis in the Behavioral Sciences[C]. 1974.
- [61] Rosenblatt F. The perceptron: a perceiving and recognizing automaton (Technical Report 85-460-1)[J]. 1957.
- [62] Rumelhart D E, Hinton G E, Williams R J. Learning representations by back-propagating errors[J]. *Nature*, 1986, 323: 533-536.
- [63] Fukushima K. Neocognitron: A self-organizing neural network model for a mechanism of pattern recognition unaffected by shift in position[J]. *Biological Cybernetics*, 1980, 36(4): 193-202.
- [64] Lecun Y, Bottou L, Bengio Y, et al. Gradient-based learning applied to document recognition[J]. *Proceedings of the IEEE*, 1998, 86(11): 2278-2324.
- [65] Krizhevsky A, Sutskever I, Hinton G E. ImageNet classification with deep convolutional neural networks[J]. *Communications of the ACM*, 2017, 60(6): 84-90.
- [66] Howard A G, Zhu M, Chen B, et al. MobileNets: Efficient Convolutional Neural Networks for Mobile Vision Applications[J].
- [67] Yu F, Koltun V, Funkhouser T. Dilated Residual Networks[C]. 2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Honolulu, HI: IEEE, 2017: 636-644.
- [68] Lv Y. manual loss backward[EB/OL]. (2023-10-31). https://github.com/AluminiumOxide/manual_loss_backward.
- [69] Hu J, Shen L, Sun G. Squeeze-and-Excitation Networks[C]. 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Salt Lake City, UT: IEEE, 2018: 7132-7141.
- [70] Li X, Wang W, Hu X, et al. Selective Kernel Networks[C]. 2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2019: 510-519.
- [71] Vaswani A, Shazeer N, Parmar N, et al. Attention Is All You Need[J]. *arXiv: 1706.03762*, 2023.
- [72] Zhang H, Xu T, Li H, et al. StackGAN: Text to Photo-Realistic Image Synthesis with Stacked Generative Adversarial Networks[J]. 2017 IEEE International Conference on Computer Vision (ICCV), 2016: 5908-5916.
- [73] Karras T, Aila T, Laine S, et al. Progressive Growing of GANs for Improved Quality, Stability, and Variation[J]. *ArXiv: 1710.10196*, 2017.

- [74] Kingma D P, Welling M. Auto-Encoding Variational Bayes[J]. arXiv: 1312.6114, 2022.
- [75] Karras T, Laine S, Aila T. A Style-Based Generator Architecture for Generative Adversarial Networks[J]. arXiv: 1812.04948, 2019.
- [76] Karras T, Laine S, Aittala M, et al. Analyzing and Improving the Image Quality of StyleGAN[J]. 2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2019: 8107-8116.
- [77] Karras T, Aittala M, Laine S, et al. Alias-Free Generative Adversarial Networks[J]. arXiv: 2106.12423, 2021.
- [78] Anoosheh A, Agustsson E, Timofte R, et al. ComboGAN: Unrestrained Scalability for Image Domain Translation[C]. 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW). Salt Lake City, UT: IEEE, 2018: 896-8967.
- [79] Choi Y, Uh Y, Yoo J, et al. StarGAN v2: Diverse Image Synthesis for Multiple Domains[J]. 2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2019: 8185-8194.
- [80] Ulyanov D, Vedaldi A, Lempitsky V. Deep Image Prior[J]. International Journal of Computer Vision, 2020, 128(7): 1867-1888.
- [81] Kang M, Zhu J Y, Zhang R, et al. Scaling up GANs for Text-to-Image Synthesis[C]. 2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Vancouver, BC, Canada: IEEE, 2023: 10124-10134.
- [82] Liao S, Lan S, Zachariah A G. EVA-GAN: Enhanced Various Audio Generation via Scalable Generative Adversarial Networks[J]. arXiv: 2402.00892, 2024.
- [83] Barron J T. A General and Adaptive Robust Loss Function[C]. 2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2019: 4326-4334.
- [84] Rudin L I, Osher S, Fatemi E. Nonlinear total variation based noise removal algorithms[J]. Physica D: Nonlinear Phenomena, 1992, 60(1): 259-268.
- [85] Wang Z, Bovik A C, Sheikh H R, et al. Image Quality Assessment: From Error Visibility to Structural Similarity[J]. IEEE Transactions on Image Processing, 2004, 13(4): 600-612.
- [86] Huang X, Belongie S. Arbitrary Style Transfer in Real-Time with Adaptive Instance Normalization[C]. 2017 IEEE International Conference on Computer Vision (ICCV). Venice: IEEE, 2017: 1510-1519.
- [87] Kaiser J F. Nonrecursive digital filter design using the I_0 -sinh window function[C]. Proc IEEE International Symposium on Circuits & Systems. 1974.
- [88] Milton A. Handbook of Mathematical Functions with Formulas, Graphs, and Mathematical Tables[J]. Am. J. Phys., 1988.

- [89] Heusel M, Ramsauer H, Unterthiner T, et al. GANs Trained by a Two Time-Scale Update Rule Converge to a Local Nash Equilibrium[J]. arXiv: 1706.08500, 2018.
- [90] Li J, Wang C, Chen T, et al. Deep learning-based quantitative optoacoustic tomography of deep tissues in the absence of labeled experimental data[J]. Optica, 2022, 9(1): 32.
- [91] Hanahan D, Weinberg R A. Hallmarks of Cancer: The Next Generation[J]. Cell, 2011, 144(5): 646-674.

发表论文和参加科研情况说明

授权专利：

- [1] 李娇,吕一品,李勇,田震,张浩. “基于闭环控制反馈的穿刺低辐射光热止血装置”, 中国发明专利, 公开号: CN118806420A。